



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ

по дисциплине «Технологии и инструментарий анализа больших данных»

Практическая работа №2
Визуализация данных в Python

Студент группы ИНБО-12-23, Албахтин И.В.

(подпись)

Преподаватель Воронцов Ю.А.

(подпись)

Москва 2026 г.

Содержание

1 Цель и выполненные задания	3
2 Источники и диагностика данных	3
3 Столбчатая диаграмма Plotly	4
4 Круговая диаграмма Plotly	5
5 Линейные графики Matplotlib	6
6 Визуализация t-SNE	7
7 Визуализация UMAP	7
8 Время и качество проекций	8
9 Выводы и ограничения	9
Практическая работа №2. Подробные ответы на контрольные вопросы	10
Источники и приложения	19

1 Цель и выполненные задания

Цель работы — выбрать визуальные представления для табличных и многомерных данных, настроить оформление Plotly и Matplotlib, исследовать t-SNE и UMAP при разных параметрах и измерить время их выполнения. Для временных и категориальных графиков использован Bike Sharing; для проекций — набор рукописных цифр load_digits. Все 11 кодовых ячеек выполнены в чистом ядре отдельной VM TIABD-Albakhtin-IV без ошибок.

2 Источники и диагностика данных

Bike Sharing содержит 731 дневное наблюдение и 16 исходных столбцов за 2011–2012 годы. Источник — UCI Machine Learning Repository, Н. Fanaee-T, DOI 10.24432/C5W894, CC BY 4.0. Признаки описывают дату, календарь, погодные условия и число прокатов случайных и зарегистрированных пользователей.

```
df = pd.read_csv(DATA_PATH, parse_dates=["dteday"])
df.head()
df.info()
df.isna().sum()
df.duplicated().sum()
assert (df.casual + df.registered == df.cnt).all()
```

Результаты приведены в таблице 1.

Таблица 1 – Первичная диагностика Bike Sharing

Показатель	Результат
Размер	731 × 16
Период	2011-01-01 — 2012-12-31
Пропуски и полные дубликаты	0 и 0
Всего прокатов	3 292 679
Среднее за день	4 504,35
Медиана	4 548
Максимум за день	8 714

Удаление или интерполяция строк не требуются. Дата имеет тип datetime; коды сезона и погоды дополнены категориальными подписями. Температура и ветер сохраняются в нормированной шкале. Влажность переводится в проценты по метаданным. Для season применены исходные

коды, поскольку архивное и обновлённое описания дают разные словесные расшифровки. Обработанная таблица сохранена в CSV и Parquet.

3 Столбчатая диаграмма Plotly

Данные сгруппированы по календарному месяцу; по X отложен месяц, по Y — сумма cnt. Цвет столбца зависит от этой же суммы. Использован модуль `plotly.graph_objects` с цветовой шкалой, чёрными границами толщиной 2, заголовком по центру размером 20, подписями осей размером 16 и метками размером 14. Угол -45° эквивалентен 315° . Высота 700 px, ширина адаптивная, сетка `ivory` толщиной 2 и минимальные внешние поля.

```
bar = go.Figure(go.Bar(
    x=monthly.index, y=monthly["cnt"],
    marker=dict(color=monthly["cnt"], coloraxis="coloraxis",
        line=dict(color="black", width=2))))
bar.update_layout(autosize=True, height=700,
    title=dict(x=0.5, font=dict(size=20)))
bar.update_xaxes(tickangle=-45, tickfont=dict(size=14),
    gridcolor="ivory", gridwidth=2)
```

На рисунке 1 представлен результат анализа.




Рисунок 1 – Число прокатов по календарным месяцам

Максимум — 2012-09: 218 573 проката. Месяцы 2012 года в целом имеют больший спрос, чем одноимённые месяцы 2011 года. Цвет повторяет количественный показатель и облегчает поиск максимумов.

4 Круговая диаграмма Plotly

Для круговой диаграммы `cnt` просуммирован по четырём кодам сезона. `go.Pie` использует читаемые подписи и проценты, чёрные границы секторов толщиной 2, согласованную цветовую схему и заголовок по центру. Категорий всего четыре, поэтому дополнительное объединение мелких объектов не требуется.

На рисунке 2 представлен результат анализа.




Рисунок 2 – Доли прокатов по исходным кодам сезона

Результаты приведены в таблице 2.

Таблица 2 – Количество прокатов по кодам сезона

Категория	Прокатов	Доля %
Код сезона 1	471 348	14,32
Код сезона 2	918 589	27,90
Код сезона 3	1 061 129	32,23
Код сезона 4	841 613	25,56

Максимум приходится на код 3. Словесные названия сезонов не используются для вывода, чтобы неоднозначность метаданных не превратилась в неверное предметное утверждение. Круговая диаграмма показывает структуру общей суммы, но не отражает хронологический порядок.

5 Линейные графики Matplotlib

По месяцу построены три связанных показателя: casual, registered и cnt. Каждый ряд показан отдельными осями одной Figure с линией crimson, белыми маркерами, чёрными границами маркеров толщиной 2 и сеткой mistyrose толщиной 2. Объектная модель Figure/Axes позволяет единообразно настроить подписи и шкалы.

На рисунке 3 представлен результат анализа.




Рисунок 3 – Месячная динамика трёх показателей спроса

Корреляция месячного cnt с registered равна 0,991, с casual — 0,922. Общий спрос теснее меняется вместе с зарегистрированной аудиторией. Это частично обусловлено арифметическим равенством $\text{cnt} = \text{casual} + \text{registered}$; показатели нельзя считать независимыми.

6 Визуализация t-SNE

Использован встроенный набор `sklearn.datasets.load_digits: 1 797` изображений десяти классов размером 8×8 пикселей, то есть 64 числовых признака на объект. Это допустимый альтернативный готовый набор по условию задания. Признаки стандартизованы; метки применяются только для цвета точек и не участвуют в обучении проекции. Все настройки используют `random_state=42`.

t-SNE выполняется для `perplexity=5, 30` и `50`. Перплексия управляет эффективным размером локального соседства. Малое значение выделяет более мелкие группы; увеличение делает структуру менее раздробленной. Расстояния между отдельными островками и их абсолютные размеры не имеют прямого смысла исходных расстояний.

На рисунке 4 представлен результат анализа.




Рисунок 4 – Проекции t-SNE для трёх значений перплексии

7 Визуализация UMAP

UMAP применяется к тем же стандартизованным объектам с тремя конфигурациями: `n_neighbors=5` и `min_dist=0,0`; `15` и `0,1`; `50` и `0,5`. Первая настройка подчёркивает очень локальные компактные группы; последняя оставляет больше пространства между точками и использует более широкое окружение. Сравнение проводится по одинаковому набору и цветовым меткам.

На рисунке 5 представлен результат анализа.




Рисунок 5 – Проекция UMAP при разных `n_neighbors` и `min_dist`

8 Время и качество проекций

Время каждого `fit_transform` измерено `time.perf_counter()`. Дополнительно рассчитана `trustworthiness` при `k=10`: она оценивает сохранение локальных соседей в двумерной проекции; выше означает лучшее сохранение этого свойства. Метрика не доказывает истинность кластеров. Первый UMAP-запуск включает JIT-компиляцию Numba, поэтому холодные и последующие измерения не полностью сопоставимы.

Результаты приведены в таблице 3.

Таблица 3 – Результаты измерения алгоритмов

Алгоритм	Параметры	Время с	Trustworthiness
t-SNE	perplexity=5	2,6018	0,9817
t-SNE	perplexity=30	2,7353	0,9861
t-SNE	perplexity=50	8,7063	0,9857
UMAP	<code>n_neighbors=5, min_dist=0.0</code>	6,2682	0,9768
UMAP	<code>n_neighbors=15, min_dist=0.1</code>	2,2638	0,9717
UMAP	<code>n_neighbors=50, min_dist=0.5</code>	4,7525	0,9468

На рисунке 6 представлен результат анализа.




Рисунок 6 – Сопоставление времени шести конфигураций

Среднее время трёх конфигураций t-SNE — 4,6811 с, UMAP — 4,4282 с. Отношение средних 0,95 включает холодный UMAP и разные настройки. Его нельзя считать универсальным коэффициентом скорости алгоритмов.

Результаты приведены в таблице 4.

Таблица 4 – Версии окружения измерений

Компонент	Версия
python	3.10.12
pandas	2.2.3
numpy	2.2.6
matplotlib	3.10.8
plotly	6.3.1
scikit_learn	1.7.2
umap_learn	0.5.9.post2

9 Выводы и ограничения

1. Для количественного сравнения месяцев подходит столбчатая диаграмма; для структуры четырёх категорий — круговая; для динамики трёх показателей — линейные графики.

2. Сумма за период составляет 3 292 679 прокатов; пик — сентябрь 2012 года. Динамика позволяет одновременно увидеть колебания внутри года и общий рост.

3. Plotly добавляет интерактивные подсказки и масштабирование; Matplotlib обеспечивает точную статическую компоновку. Для каждой библиотеки выполнены требования оформления из задания.

4. t-SNE и UMAP показывают разделение известных классов цифр, но форма и плотность островков меняются при смене параметров.

5. Trustworthiness дополняет визуальный анализ измеримой оценкой локальных соседств. Она не оценивает все аспекты сохранения геометрии и не заменяет предметную интерпретацию.

6. Измерения зависят от прогрева Numba, размера набора и нагрузки. Результат одной серии на 1 797 объектах не переносится без проверки на более крупные данные.

Ограничения: Bike Sharing относится к одному городу и двум годам; исходная расшифровка сезонов неоднозначна. Двумерные нелинейные проекции теряют часть информации и не являются доказательством существования истинных кластеров.

Практическая работа №2. Подробные ответы на контрольные вопросы

1. Из каких основных объектов состоит график Matplotlib?

Простыми словами. График Matplotlib устроен как набор вложенных объектов. Figure — весь лист или холст. Axes — отдельная область, где строятся данные. Axis — конкретная координатная ось X или Y с диапазоном, делениями и подписями. Линии, точки, текст, легенда и другие видимые элементы называются Artist.

Как это работает. Команда `fig, ax = plt.subplots()` создаёт Figure и один Axes. Затем `ax.plot(...)` добавляет линию именно в эту область. У `ax` есть две оси: `ax.xaxis` и `ax.yaxis`. Если написать `plt.subplots(2, 2)`, одна Figure будет содержать четыре Axes, то есть четыре отдельных подграфика.

Пример и вывод. В практической работе рисунок с тремя временными рядами состоит из одной Figure и трёх Axes. Заголовок всего рисунка относится к Figure, а название каждого подграфика — к соответствующему

Axes. Такое разделение важно для понимания объектного интерфейса: мы изменяем конкретную часть рисунка, а не «график вообще».

2. Чем интерфейс `pyplot` отличается от объектного интерфейса `Matplotlib`?

Простыми словами. `pyplot` — набор команд, похожий на работу с текущим активным рисунком: `plt.plot()`, `plt.title()`, `plt.xlabel()`. Объектный интерфейс сначала создаёт объекты `fig` и `ax`, а затем явно вызывает их методы: `ax.plot()`, `ax.set_title()`, `ax.set_xlabel()`.

Как это работает. `pyplot` хранит внутреннее состояние и решает, какой рисунок сейчас считается текущим. Для одного простого графика это удобно и коротко. При нескольких подграфиках легко случайно изменить не ту область. Объектный интерфейс не полагается на скрытое состояние: переменная `ax` однозначно указывает, куда добавляется линия, сетка или подпись.

Пример и вывод. В цикле можно написать `for ax, column in zip(axes, columns): ax.plot(...)` и настроить каждую панель отдельно. Поэтому для отчётов, сложных композиций и повторно используемых функций предпочтителен объектный интерфейс. `pyplot` всё равно применяется для создания `Figure` и быстрого показа, но основная настройка выполняется через объекты.

3. Зачем явно вызывать `figure()` или `subplots()`?

Простыми словами. Эти функции создают новый рисунок и позволяют заранее определить его размер и устройство. Без явного создания `Matplotlib` может использовать уже активный рисунок, из-за чего новый график случайно наложится на старый или получит неподходящий размер.

Как это работает. `plt.figure(figsize=(8, 5))` создаёт `Figure` размером 8 на 5 дюймов, после чего `pyplot` работает с ней как с текущей. `fig, ax = plt.subplots()` одновременно создаёт `Figure` и `Axes`. Параметры `nrows` и `ncols` задают сетку подграфиков, а `figsize` — физический размер всего рисунка.

Пример и вывод. Для трёх рядов Bike Sharing используется `plt.subplots(3, 1, ...)`: три области располагаются вертикально и делят общую временную ось. Явное создание делает код воспроизводимым: размер, число панелей и объект, который изменяется, видны непосредственно в программе.

4. Для чего используется `zorder`?

Простыми словами. `zorder` задаёт, какой объект рисуется поверх другого. Это похоже на слои в графическом редакторе: объект с большим значением находится ближе к зрителю, с меньшим — позади.

Как это работает. Если линия, точки и сетка занимают одно место, порядок их отрисовки влияет на читаемость. Например, сетке можно задать `zorder=0`, столбцам `zorder=2`, а подписям `zorder=3`. Значение не меняет координаты данных, толщину или цвет; оно влияет только на перекрытие элементов.

Пример и вывод. На scatter plot крупные точки могут закрывать линию тренда. Если линии задать больший `zorder`, она останется видимой. Параметр особенно полезен для фоновой сетки, выделенных наблюдений, доверительных интервалов и аннотаций. Следует задавать его осмысленно, иначе важные элементы могут оказаться скрытыми.

5. В чём различие Plotly Express и `graph_objects`?

Простыми словами. Plotly Express — высокоуровневый интерфейс: одна функция быстро строит типовой график из `DataFrame`. `graph_objects` — низкоуровневый интерфейс, где рисунок собирают из отдельных следов и подробно настраивают макет.

Как это работает. В Express можно написать `px.bar(df, x="month", y="cnt", color="cnt")`, и библиотека сама создаст `Figure`, следы, легенду и подписи. В `graph_objects` создают `go.Figure()`, добавляют `go.Bar`, `go.Scatter` или другие `trace`-объекты, а затем вызывают `update_layout()` и `update_xaxes()`. Кода больше, зато доступно больше деталей.

Пример и вывод. В этой работе `go.Bar` используется для явной настройки границ столбцов, цветовой шкалы, высоты и полей рисунка. `Express` удобен для разведочного анализа и быстрых графиков. `graph_objects` лучше подходит, когда нужны несколько типов следов, вторичная ось, сложные `hover`-подсказки или точное оформление.

6. Почему Plotly называют интерактивной библиотекой?

Простыми словами. Пользователь может взаимодействовать с готовым рисунком, а не только смотреть на статичную картинку. В браузере доступны наведение мыши, увеличение, перемещение области просмотра, включение и выключение рядов и сохранение изображения.

Как это работает. Plotly преобразует описание `Figure` в JavaScript-график. Данные и настройки могут быть сохранены в HTML вместе с кодом визуализации. Поэтому для просмотра такого файла не требуется запущенный Python: браузер выполняет интерактивную часть самостоятельно. В notebook график отображается через встроенный HTML/JavaScript-рендерер.

Пример и вывод. На столбчатой диаграмме можно навести курсор на месяц и увидеть точное число поездок, а затем приблизить интересующий период. Интерактивность полезна при исследовании данных. Для печатного отчёта всё равно нужна статическая версия, потому что наведение и масштабирование на бумаге недоступны.

7. Что показывает цветовая шкала в столбчатой диаграмме этой работы?

Простыми словами. Цвет каждого столбца кодирует то же значение, что и его высота: месячное число поездок. Низкие значения показаны одним краем шкалы, высокие — другим. Справа расположена легенда, связывающая цвет с числом.

Как это работает. В `go.Bar` массив `monthly["cnt"]` передан одновременно в `y` и в `marker.color`. Параметр `coloraxis="coloraxis"` подключает общую непрерывную шкалу. Такое кодирование называют избыточным, потому что один показатель выражается двумя визуальными каналами.

Пример и вывод. Высокий жёлтый столбец сентября 2012 года одновременно выделяется высотой и цветом. Это ускоряет поиск максимумов, но цвет не добавляет новый признак. Если цвет должен был показывать год или сезон, в `marker.color` нужно было бы передать соответствующую категорию и использовать дискретную легенду.

8. Почему круговую диаграмму не следует перегружать категориями?

Простыми словами. В круговой диаграмме величины сравниваются по углам и площадям секторов. Человек делает такое сравнение менее точно, чем сравнение длины столбцов. Когда секторов много, они становятся узкими, цвета повторяются, а подписи сталкиваются.

Как это работает. Круг хорошо читается, если категорий мало, их сумма действительно образует целое и различия достаточно заметны. При десяти похожих долях зритель уже не может уверенно определить порядок. Маленькие сектора почти исчезают, а вынесенные подписи занимают больше места, чем сами данные.

Пример и вывод. В практической работе всего четыре сезона, поэтому круговая диаграмма остаётся понятной и показывает долю каждого сезона в общем числе поездок. Если бы категорий было двадцать, лучше использовать отсортированную горизонтальную `bar chart`. Редкие категории иногда объединяют в «Другие», но только если это не скрывает важный смысл.

9. Как выбирать между Matplotlib и Plotly?

Простыми словами. Выбор определяется тем, где и как будет использоваться график. Matplotlib удобен для статических изображений и точного контроля над каждой деталью. Plotly удобен, когда пользователь должен исследовать рисунок в `notebook` или браузере.

Как это работает. Matplotlib хорошо экспортирует PNG, SVG и PDF, поддерживает сложные научные композиции и обычно предсказуем в печатных документах. Plotly автоматически предоставляет `hover`-подсказки, масштабирование, панорамирование и управление легендой. За это

приходится платить более тяжёлым HTML и зависимостью от браузерного JavaScript.

Пример и вывод. Месячные ряды в отчёте сделаны Matplotlib, потому что важна статическая трёхпанельная композиция. Столбчатая и круговая диаграммы Plotly удобны для просмотра точных значений. Часто используют обе библиотеки: Plotly — на этапе исследования, Matplotlib — для окончательной иллюстрации в отчёте.

10. Какую задачу решает снижение размерности?

Простыми словами. Объект может описываться десятками или тысячами признаков, но человек способен непосредственно увидеть только две или три координаты. Снижение размерности преобразует исходные признаки в меньшее число новых координат, стараясь сохранить важные отношения между объектами.

Как это работает. Алгоритм получает матрицу, где строки — объекты, а столбцы — признаки. На выходе он создаёт, например, две координаты для каждой строки. Разные методы сохраняют разную структуру: PCA ориентируется на общую линейную вариативность, t-SNE — на локальные соседства, UMAP — на граф соседей и сочетание локальной и более общей структуры.

Пример и вывод. Каждая рукописная цифра в `load_digits` описана 64 интенсивностями пикселей. t-SNE и UMAP превращают эти 64 признака в две координаты, чтобы точки можно было показать на плоскости. Проекция помогает увидеть группы и ошибки, но не хранит всю исходную информацию и не заменяет количественную проверку.

11. Что означает перплексия в t-SNE?

Простыми словами. Перплексия приблизительно задаёт, сколько ближайших соседей алгоритм учитывает при описании локального окружения каждой точки. Это не точное число соседей, но полезная интуиция для выбора масштаба анализа.

Как это работает. t-SNE преобразует расстояния между объектами в вероятности соседства. Для каждой точки подбирается ширина локального распределения так, чтобы его эффективный размер соответствовал перплексии. Малое значение сильнее ориентируется на очень близкие точки и может раздробить данные. Большое значение учитывает более широкое окружение и сглаживает мелкие детали.

Пример и вывод. В работе проверены значения 5, 30 и 50. При 5 группы распадаются на более мелкие фрагменты; 30 и 50 дают более цельные классы. Перплексия должна быть заметно меньше числа объектов, а вывод желательно проверять на нескольких значениях, потому что одна картинка может отражать настройку алгоритма, а не устойчивую структуру данных.

12. Почему для t-SNE нужно фиксировать `random_state`?

Простыми словами. t-SNE использует случайность при начальном размещении точек и в процессе оптимизации. Поэтому два запуска с одинаковыми данными и параметрами могут дать повёрнутые, отражённые или иначе расположенные группы.

Как это работает. `random_state=42` задаёт начальное состояние генератора псевдослучайных чисел. При одинаковых версиях библиотек, данных и параметрах запуск становится повторяемым. Число 42 не обладает специальными свойствами; можно выбрать другое фиксированное целое значение.

Пример и вывод. Если сравниваются перплексии 5, 30 и 50, случайное состояние должно быть одинаковым. Иначе различия между рисунками частично объяснялись бы разной случайной инициализацией. Фиксация `random_state` нужна для честного эксперимента и воспроизводимого отчёта, но не гарантирует совпадение между сильно различающимися версиями библиотек или платформами.

13. Можно ли трактовать расстояния и размеры кластеров t-SNE буквально?

Простыми словами. Нет. t-SNE старается расположить близких соседей рядом, но не обязан сохранять точные расстояния между далёкими группами, их площадь, ориентацию или относительное положение на плоскости.

Как это работает. Для размещения всех точек в двух измерениях алгоритм искажает исходную геометрию. Плотность группы на картинке зависит от параметров и оптимизации. Два кластера могут выглядеть далеко друг от друга, хотя в исходном пространстве это расстояние не имеет такого масштаба. Поворот или зеркальное отражение всей проекции вообще не меняет её смысла.

Пример и вывод. На рисунке цифры 3 и 9 могут находиться рядом из-за похожих пиксельных шаблонов, но расстояние в сантиметрах между их облаками нельзя использовать как числовую меру сходства. Надёжнее анализировать локальных соседей, проверять несколько запусков и использовать метрики в исходном 64-мерном пространстве.

14. За что отвечают `n_neighbors` и `min_dist` в UMAP?

Простыми словами. `n_neighbors` определяет размер окружения, которое UMAP рассматривает вокруг каждой точки. `min_dist` задаёт, насколько близко точки могут располагаться в готовой проекции. Первый параметр управляет масштабом структуры, второй — визуальной плотностью групп.

Как это работает. При малом `n_neighbors` алгоритм сильнее сохраняет очень локальные отношения и может показать много небольших групп. При большом значении учитывается более широкое окружение, поэтому проявляется общая структура. Малый `min_dist` разрешает точкам собираться в плотные кластеры; большой оставляет между соседями больше пространства.

Пример и вывод. В конфигурации `n_neighbors=5`, `min_dist=0.0` цифры образуют компактные островки. При `n_neighbors=50`, `min_dist=0.5` облака становятся шире. Эти параметры не означают «правильное число кластеров»

и не выбираются только по красоте: настройки сравнивают по устойчивости, метрике *trustworthiness* и цели анализа.

15. Почему первое измерение времени UMAP может быть завышено?

Простыми словами. Библиотека UMAP использует Numba, которая переводит часть Python-кода в быстрый машинный код во время первого запуска. Компиляция занимает время, поэтому первый вызов включает и подготовку, и само вычисление.

Как это работает. Такой запуск называют «холодным». При следующих вызовах скомпилированные функции уже находятся в памяти или кэше, и измеряется в основном работа алгоритма. На время также влияют загрузка процессора, число потоков, размер данных, параметры и версии библиотек. Поэтому одно число без описания окружения мало что доказывает.

Пример и вывод. В работе первая конфигурация UMAP выполнялась заметно дольше двух последующих. Для честного сравнения полезно отдельно показать холодный запуск, выполнить прогрев, повторить измерение несколько раз и использовать медиану. Нельзя делать общий вывод «UMAP всегда медленнее t-SNE» по одному небольшому набору.

16. Почему двумерная визуализация не доказывает существование истинных кластеров?

Простыми словами. При переходе из 64 измерений в 2 часть информации неизбежно теряется. Алгоритм вынужден раздвигать одни точки и сближать другие. Поэтому на плоскости могут появиться убедительные островки даже тогда, когда в исходных данных нет чётких естественных границ.

Как это работает. t-SNE и UMAP специально оптимизируют вид соседств, а выбранные параметры влияют на плотность и разделение групп. Цветные метки также усиливают впечатление упорядоченности. Настоящий кластер должен подтверждаться не только картинкой, но и устойчивостью к параметрам, метриками качества, результатами других методов и предметным смыслом признаков.

Пример и вывод. Для `load_digits` известны правильные классы цифр, поэтому цвет помогает оценить, смешиваются ли похожие изображения. В реальной задаче меток может не быть. Тогда 2D-проекцию используют как источник гипотез: находят кандидатов на группы, а затем проверяют их в исходном пространстве и на новых данных.

Источники и приложения

Методическое задание «Практика №2» — визуализация данных в Python, восемь пунктов задания.

Bike Sharing. UCI Machine Learning Repository.
<https://doi.org/10.24432/C5W894>. CC BY 4.0.

`sklearn.datasets.load_digits` — встроенный набор рукописных цифр. Выполненный Notebook, CSV с измерениями, шесть PNG и два интерактивных HTML приложены к работе.