Лекция 7. Компьютерное зрение и обработка больших коллекций изображений

Технологии и инструментарий анализа больших данных

Курс ТИАБД



Раздел

Введение

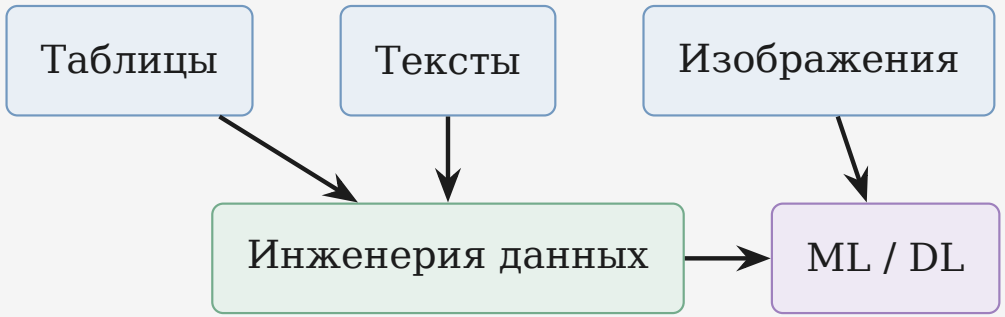


Место лекции в курсе Big Data

До этого момента мы работали с таблицами, признаками, текстами и языковыми моделями. Теперь рассматриваем другой фундаментальный класс неструктурированных данных – **изображения**.

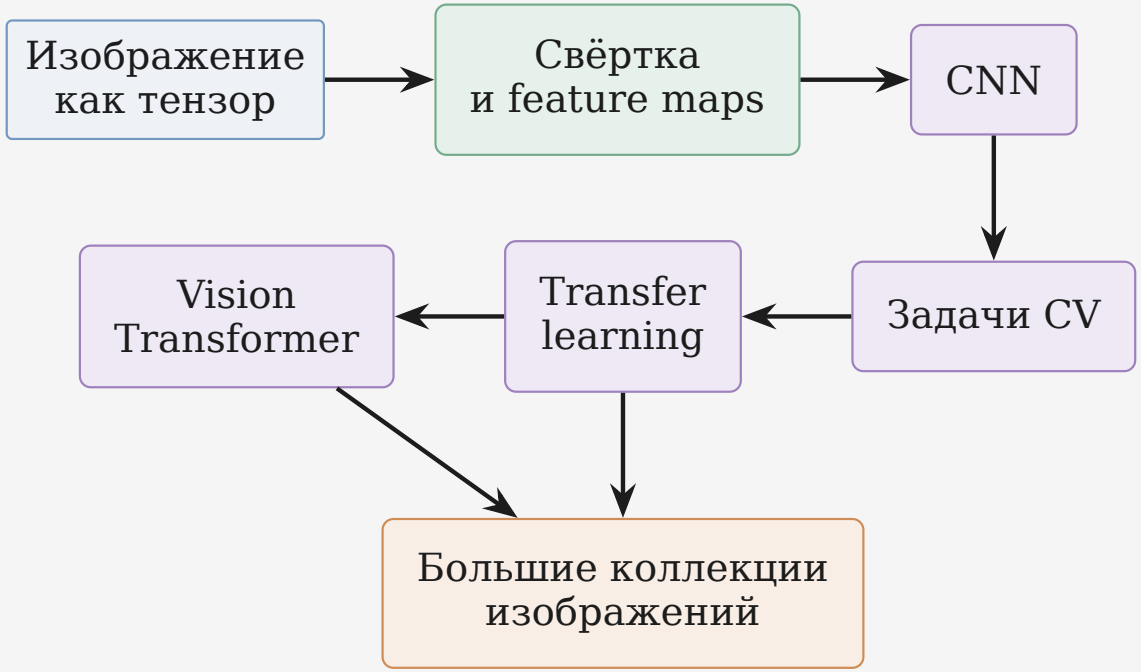
Главная идея

Для человека изображение является визуальным триггером. Для вычислительной системы после декодирования это многомерный массив чисел, который нужно хранить, читать, преобразовывать, группировать в пакеты и обрабатывать моделью.



Компьютерное зрение в данном курсе изучается не изолированно, а как часть современной аналитической платформы.

Логика лекции



Результат

После лекции научимся объяснить не только «как работает CNN», но и почему обучение на больших наборах изображений требует отдельной инженерной организации данных.

Раздел

Изображение как тензор



Цифровое изображение

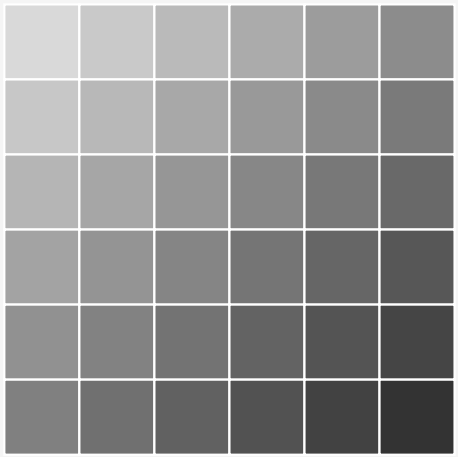
На самом нижнем уровне цифровое изображение задаётся значениями пикселей.

Grayscale

Полутоновое изображение можно представить матрицей:

$$I \in \mathbb{R}^{H \times W}.$$

Каждый элемент $I_{i,j}$ описывает интенсивность пикселя.



матрица яркостей

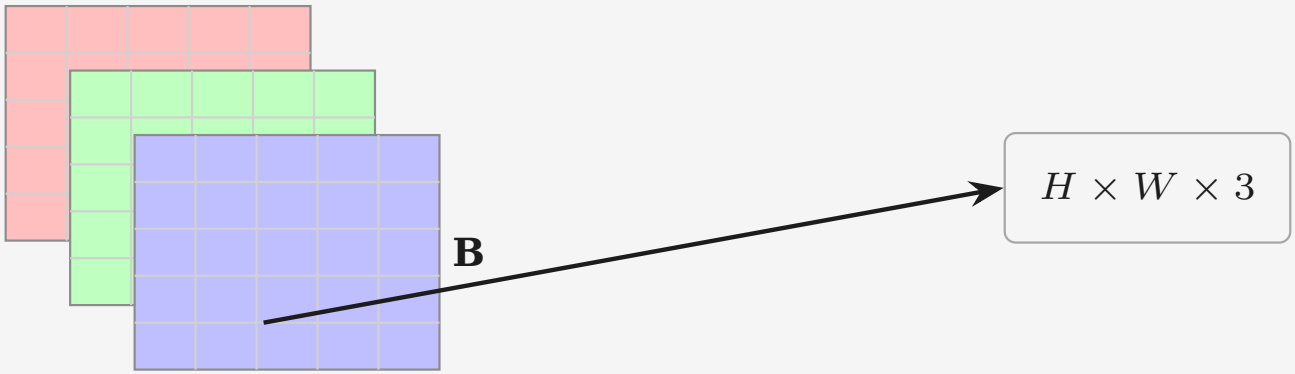
Не путать файл и тензор

JPEG/PNG — это формат хранения на диске. Нейронная сеть обычно получает декодированный числовой массив.

RGB-изображение

Цветное изображение хранит три канала: красный, зелёный и синий.

$$I \in \mathbb{R}^{H \times W \times 3}.$$

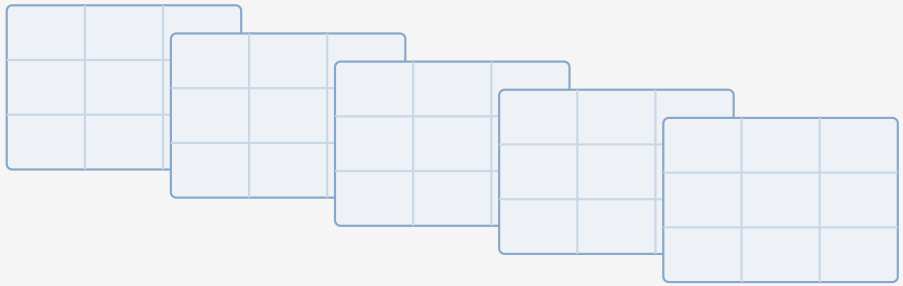


Формат каналов может быть $H \times W \times C$ или $C \times H \times W$ в зависимости от библиотеки, но смысл остается один – изображение это тензор.

Пакет изображений

В машинном обучении модель почти всегда получает не одно изображение, а пакет изображений.

$$X \in \mathbb{R}^{N \times C \times H \times W}.$$



$$N \times C \times H \times W$$

N изображений в одном batch

Инженерный смысл batch

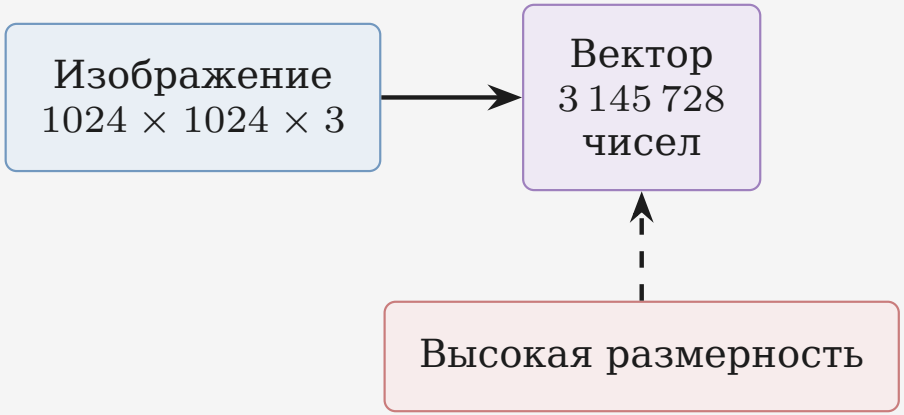
Batch позволяет эффективно использовать векторные операции CPU/GPU, но требует согласования размеров, нормализации, формирования мини-пакетов и контроля памяти.

Размерность изображения

Даже одно изображение быстро превращается в большой вектор чисел.

Для RGB-изображения размера 1024×1024:

$$1024 \cdot 1024 \cdot 3 = 3\,145\,728.$$



Это более трёх миллионов числовых компонент на один объект наблюдения.

Проблема

Если применить к такому вектору обычную полносвязную сеть, число параметров первого слоя может стать чрезвычайно большим.

Почему обычная полносвязная сеть не является естественным решением

Пусть вход имеет $D = HWC$ компонент, а первый скрытый слой содержит M нейронов. Тогда матрица весов имеет размер

$$W \in \mathbb{R}^{M \times D}, \qquad N_{params} = M \cdot D.$$

Для $D = 3\,145\,728$ и $M = 1000$ получаем примерно

$$3.1 \cdot 10^9$$

весов только в первом слое.

Нужна модель, которая использует пространственную структуру изображения, а не игнорирует её.



Раздел

Локальная структура и свёртка

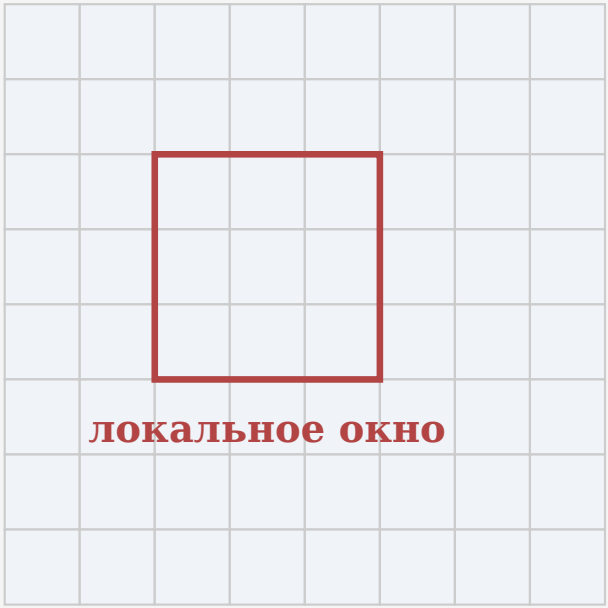


Локальность изображения

В изображении соседние пиксели обычно сильнее связаны друг с другом, чем далёкие пиксели.

Локальная связность

Модель не обязана сразу соединять каждый пиксель со всеми остальными. Достаточно анализировать небольшие локальные области, а затем постепенно собирать более сложные признаки.



Свёртка смотрит
не на весь вектор,
а на небольшую
область изображения.



Математическая запись свертки

Свёртка применяет небольшой фильтр K к локальной области входного изображения X.

$$Y_{i,j} = \sum_m \sum_n X_{i+m,j+n} K_{m,n}.$$

Ядро

Небольшая матрица весов, например 3×3 или 5×5. Одно и то же ядро применяется ко многим позициям изображения.

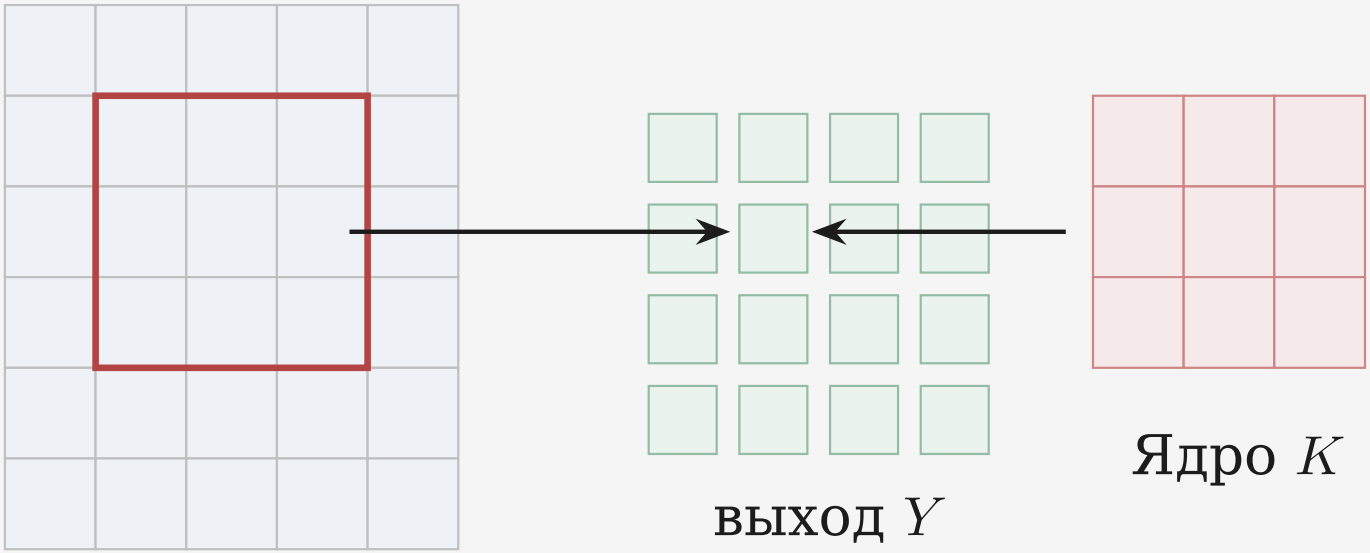
Карта признаков

Результат применения фильтра ко всем допустимым позициям изображения. Разные фильтры формируют разные карты признаков.

В глубоком обучении значения ядра не задаются вручную, а обучаются по данным.



Свёртка как скользящее окно

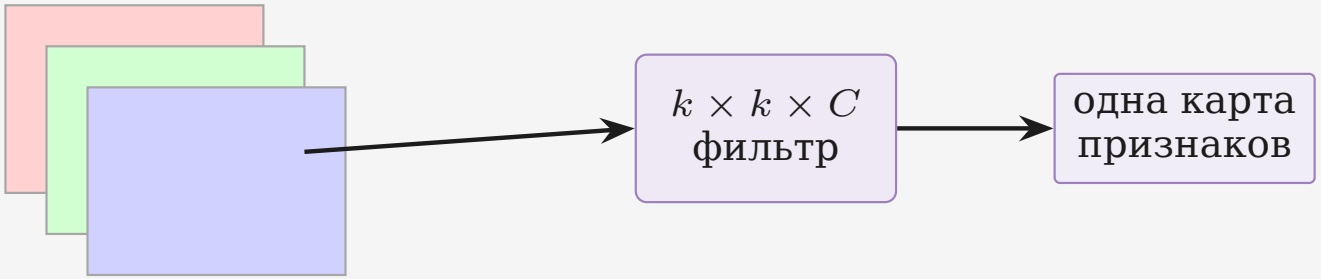


Смысл операции

Фильтр последовательно «просматривает» изображение, вычисляя локальные отклики. Высокий отклик означает, что в данной области обнаружен соответствующий шаблон.

Совместная обработка каналов

Для RGB-входа ядро имеет глубину по каналам. Если вход имеет C каналов, то один фильтр размера $k \times k$ содержит $k \cdot k \cdot C$ обучаемых весов.



входные каналы

Если используется несколько фильтров, получается несколько выходных карт признаков.



Stride

Stride — шаг, с которым ядро перемещается по изображению.

Stride = 1

Фильтр смещается на один пиксель. Выходное изображение сохраняет больше пространственной информации, но вычислений больше.

Stride > 1

Фильтр пропускает позиции. Размер выхода уменьшается, вычислений меньше, но часть пространственной детализации теряется.

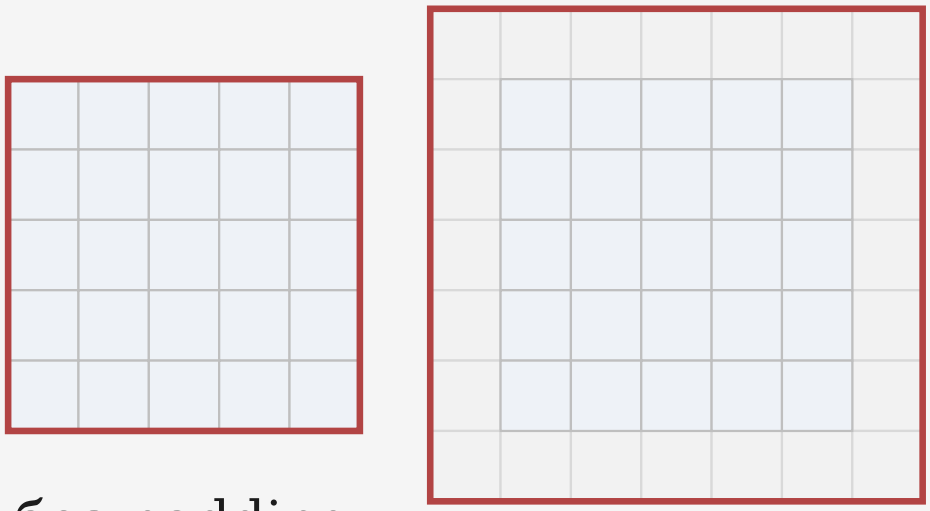
$$H_{out} = \left\lfloor \frac{H + 2P - K}{S} \right\rfloor + 1, \qquad W_{out} = \left\lfloor \frac{W + 2P - K}{S} \right\rfloor + 1.$$

Здесь K — размер фильтра, P — padding, S — stride.



Padding

Padding добавляет искусственную рамку вокруг изображения.



без padding

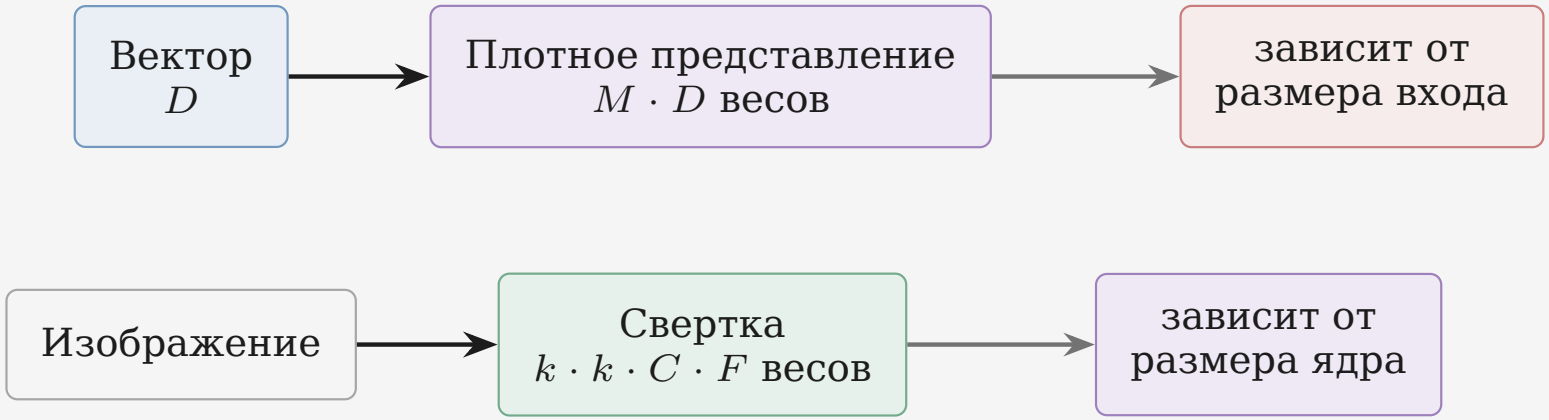
с padding

Зачем нужен padding

Padding позволяет управлять размером выхода и не терять информацию по краям изображения слишком быстро.

Почему свёртка экономит параметры

В полносвязном слое каждый выходной нейрон имеет собственные веса ко всем входным компонентам. В свёртке один и тот же небольшой фильтр используется во многих позициях.



Ключ

Свёртка использует **разделение весов** и **локальную связность**. Это делает её естественной операцией для изображений.

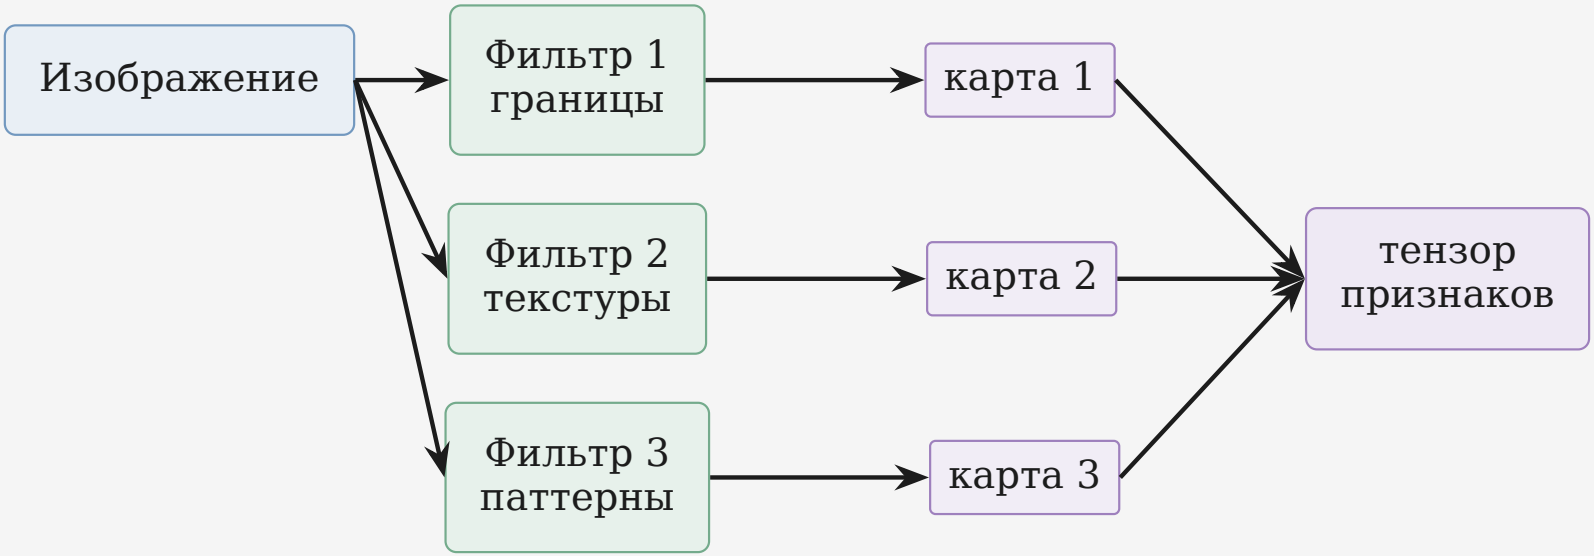
Раздел

Карты признаков, нелинейность и пулинг



Feature maps

Каждый фильтр формирует свою карту признаков.

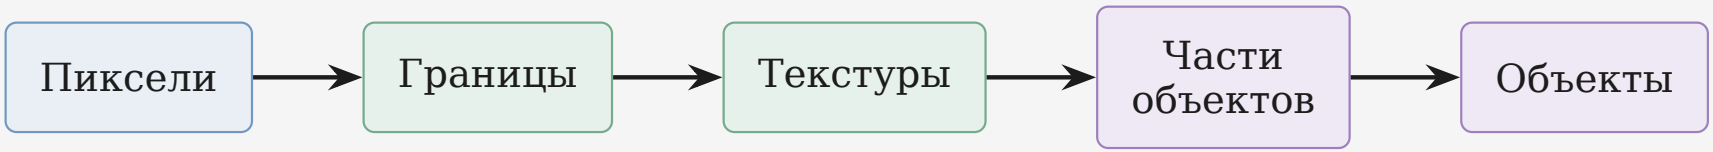


Глубокая сеть учится сама выбирать фильтры, полезные для целевой задачи.



Иерархия признаков

CNN строит признаки постепенно от простых локальных паттернов к более сложным объектным структурам.



Интерпретация

Ранние слои обычно чувствительны к низкоуровневым признакам. Более глубокие слои работают с абстрактными представлениями, полезными для классификации, поиска, детекции или сегментации.



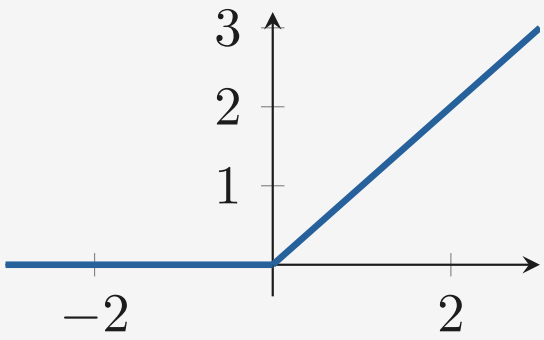
Нелинейность ReLU

После свёртки обычно применяется нелинейная функция активации, например ReLU:

$$\mathrm{ReLU}(x) = \max(0, x).$$

Зачем нужна нелинейность

Без нелинейностей композиция слоёв оставалась бы линейным преобразованием. Нелинейность позволяет строить сложные разделяющие поверхности и сложные представления.

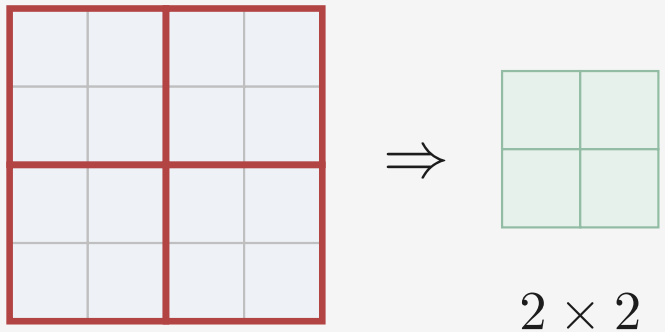




Pooling

Pooling уменьшает пространственный размер карты признаков. Наиболее известный вариант — max pooling.

$$Y_{i,j} = \max_{(m,n)\in\Omega_{i,j}} X_{m,n}.$$



Смысл

Pooling снижает размерность, уменьшает вычислительную стоимость и создаёт ограниченную локальную инвариантность к малым сдвигам.

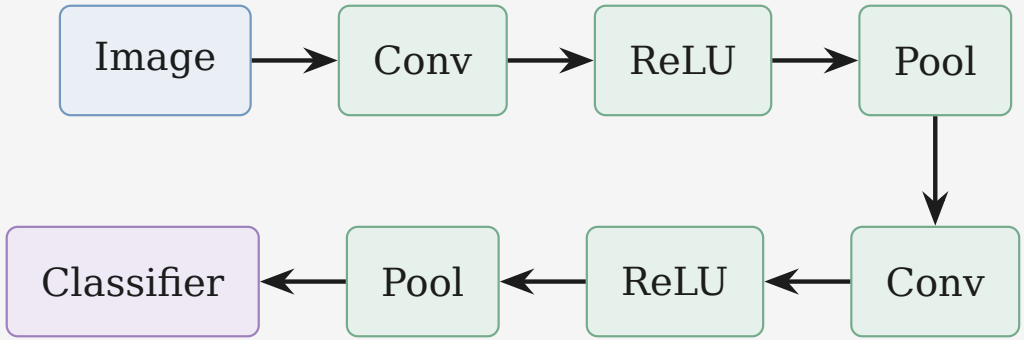
Раздел

CNN и основные задачи компьютерного зрения



Типичная CNN-архитектура

Классическая сверточная сеть чередует свёртки, нелинейности и операции уменьшения размера, а затем передаёт итоговое представление в классификатор.



Важно

CNN не «видит» изображение как человек. Она строит последовательность числовых представлений, полезных для минимизации функции потерь.

Backbone и голова

В современных CV-моделях удобно различать две части.



Backbone

Общая часть модели, которая переводит изображение в признаки. Часто переносится из предобученной модели.

Голова

Зависит от конкретной задачи. Классификация требует одного типа выхода, детекция и сегментация — другого.

Классификация изображения

Image classification сопоставляет изображению один или несколько классов.

$$f(I) \to \{c_1, \ldots, c_K\}.$$



Примеры

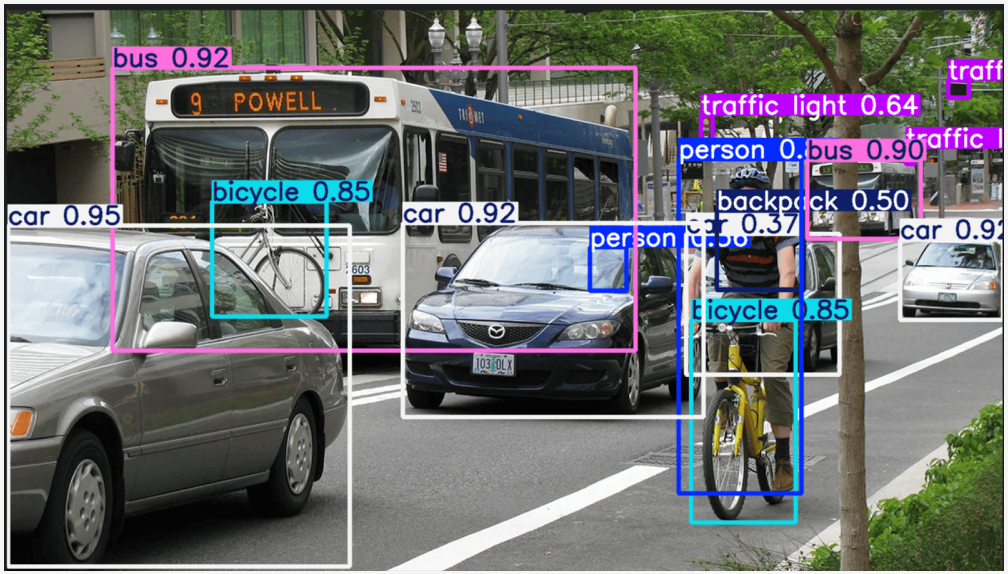
Классификация дефектов на производстве, определение категории товара по фото, медицинская сортировка изображений, фильтрация пользовательского контента.



Детекция объектов

Object detection должна не только определить класс объекта, но и локализовать его рамкой.

$$I \to \{(class_i, bbox_i, score_i)\}_{i=1}^{M}.$$

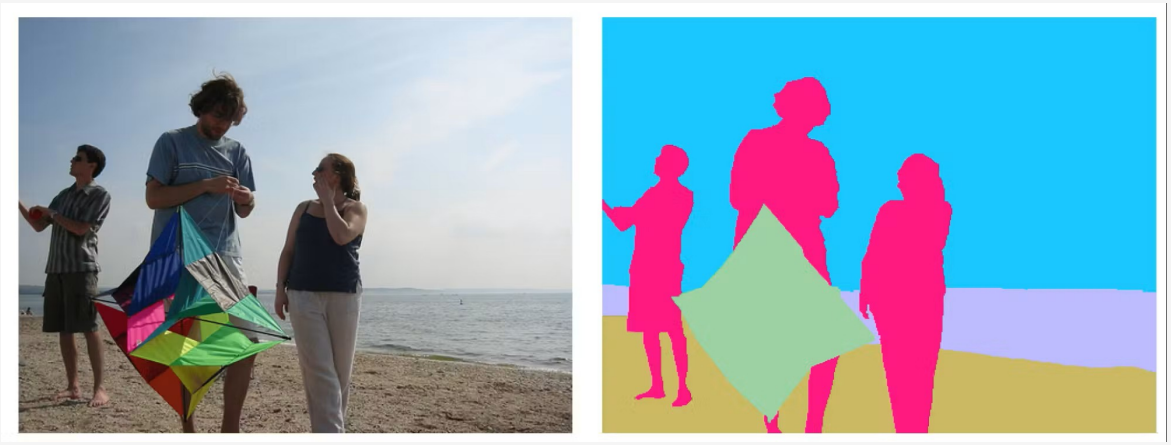


Детекция сложнее классификации, так как модель должна решать задачу распознавания и задачу локализации одновременно.

Семантическая сегментация

Semantic segmentation назначает класс каждому пикселю изображения.

$$I \in \mathbb{R}^{H \times W \times C} \to Y \in \{1, \ldots, K\}^{H \times W}.$$

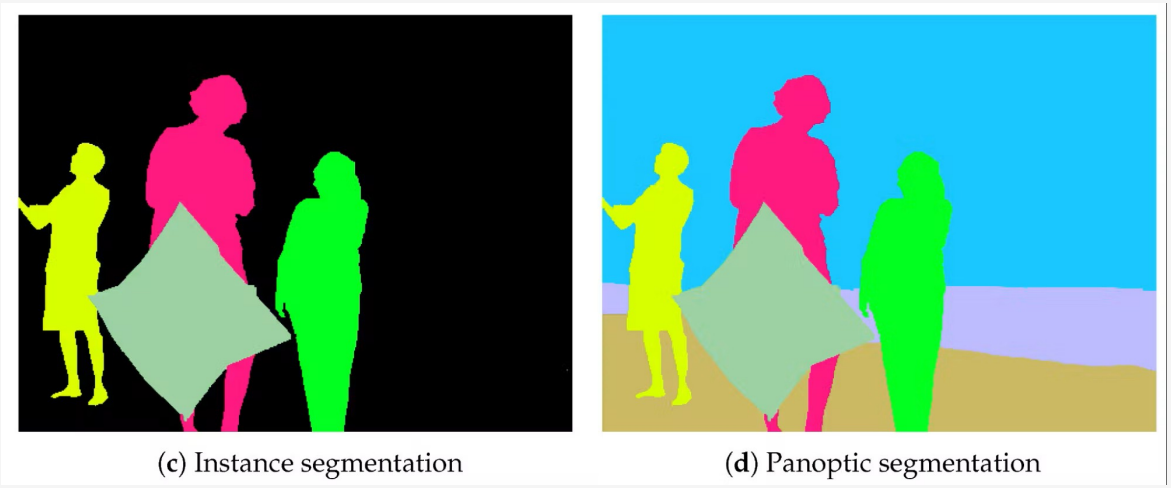


Примеры

Медицинские снимки, спутниковые изображения, дорожные сцены, промышленный контроль поверхности.

Instance Segmentation

Instance segmentation не только классифицирует пиксели, но и разделяет отдельные экземпляры объектов одного класса.



(c) Instance segmentation (d) Panoptic segmentation

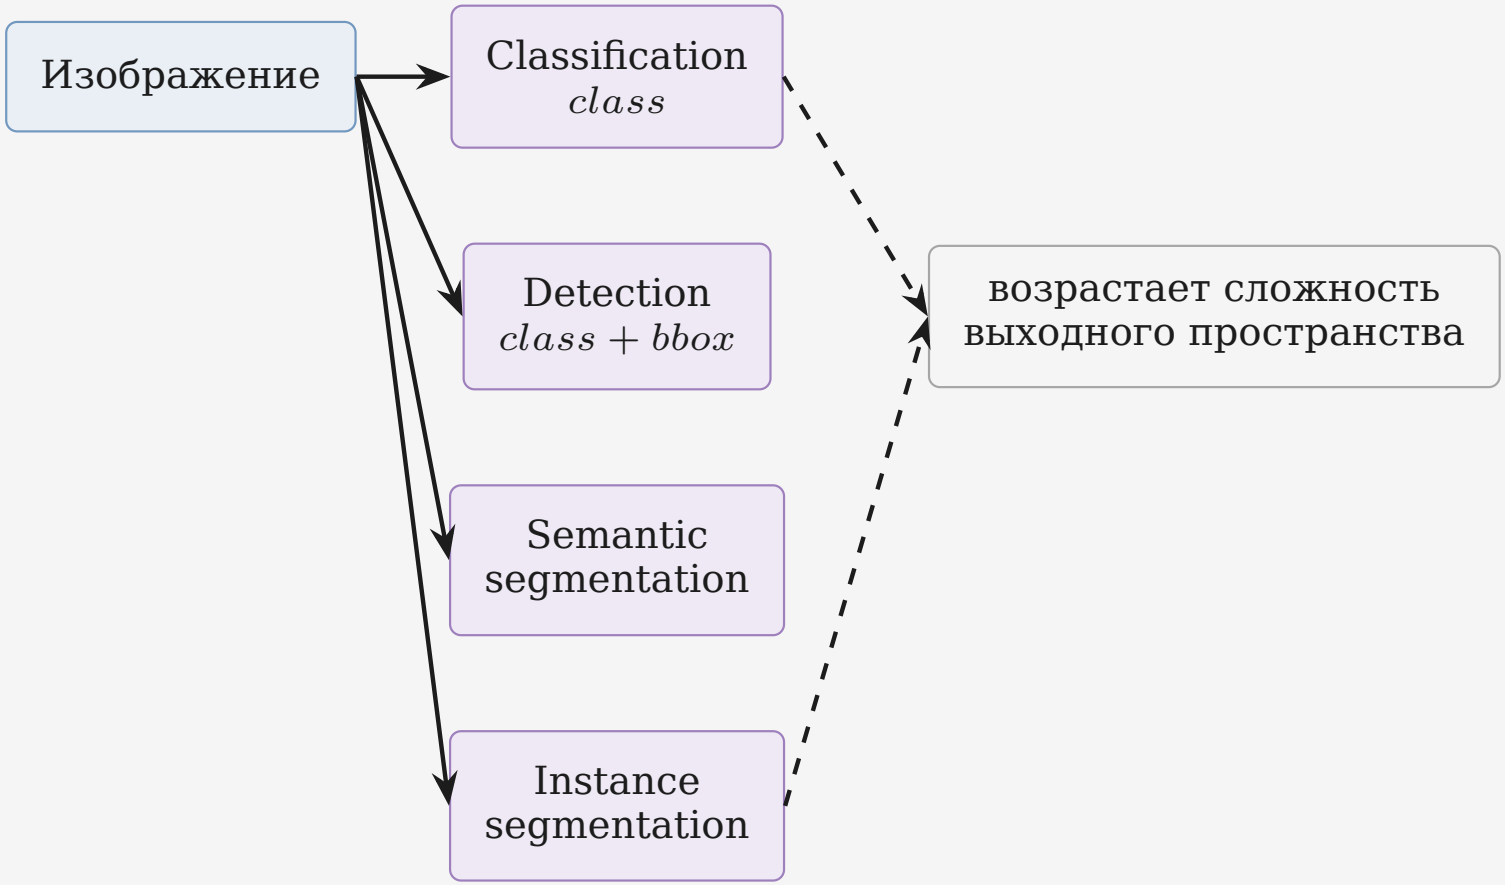
Semantic segmentation

Все пиксели класса «автомобиль» имеют один общий класс.

Instance segmentation

Модель различает «автомобиль 1», «автомобиль 2», «автомобиль 3».

Сводная карта задач CV



Задача определяет архитектуру последней части модели, формат разметки и метрики качества.

Раздел

Перенос знаний

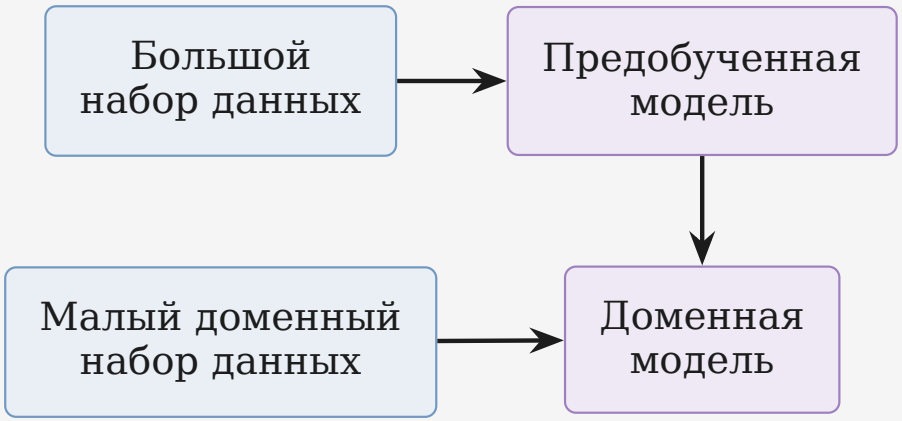


Почему перенос знаний особенно важен

Обучение большой CV-модели с нуля требует большого размеченного датасета и значительных вычислительных ресурсов. В условиях учебного курса и ограниченных устройств это нерационально.

Transfer learning

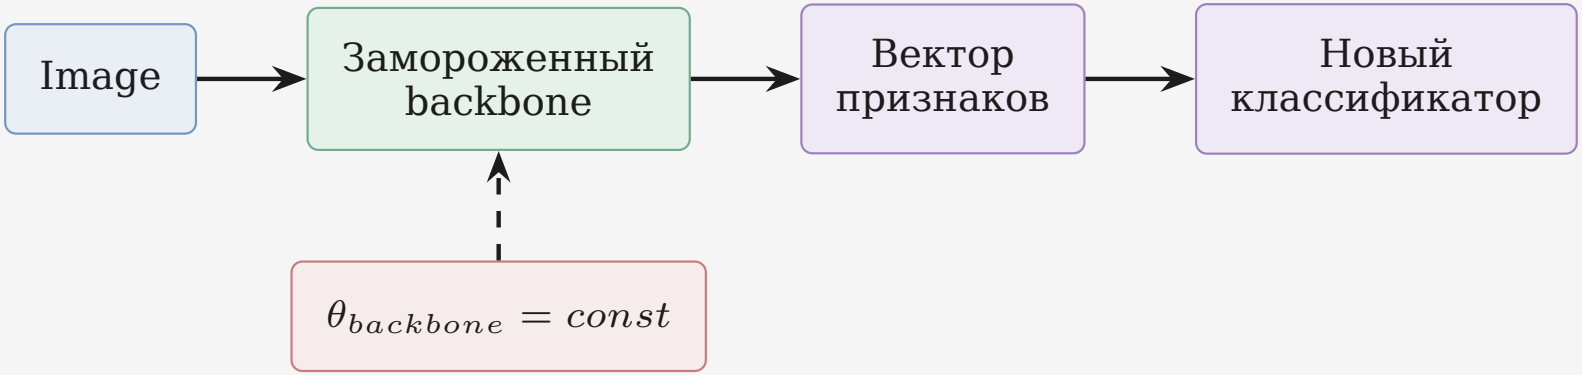
Использование модели, заранее обученной на большом датасете, для решения новой, обычно более узкой задачи.





Стадия извлечения признаков

Первый режим переноса знаний — использовать предобученную сеть как извлекатель признаков.



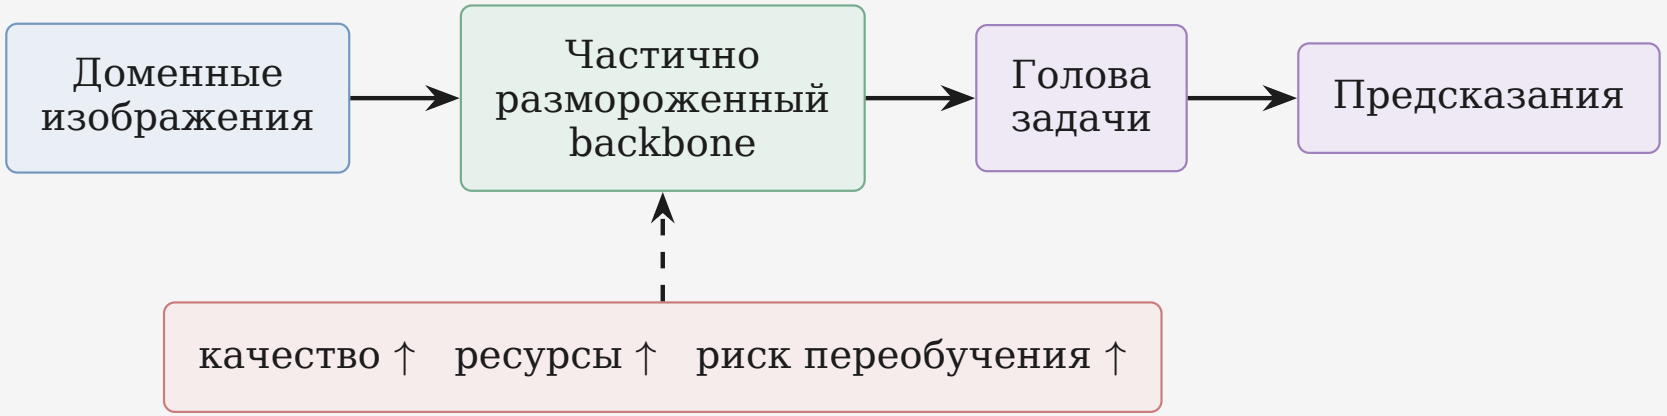
Смысл

Мы не меняем веса backbone. Обучается только небольшой классификатор поверх уже извлечённых признаков.

Такой подход особенно полезен, если данных мало или вычислительные ресурсы ограничены.

Дообучение

Второй режим — дообучать часть или всю предобученную модель на доменном датасете.



Компромисс

Дообучение может дать лучшее качество, но требует осторожного выбора скорости обучения, числа размороженных слоёв и стратегии регуляризации.



Что переносится при переносе знаний

Предобученная модель переносит не сами классы исходного датасета, а параметры, формирующие полезные визуальные представления.

Низкоуровневые признаки

Границы, углы, цветовые переходы, простые текстуры. Обычно применимы к разным доменам.

Высокоуровневые признаки

Части объектов и семантические структуры. Могут сильнее зависеть от исходного датасета.



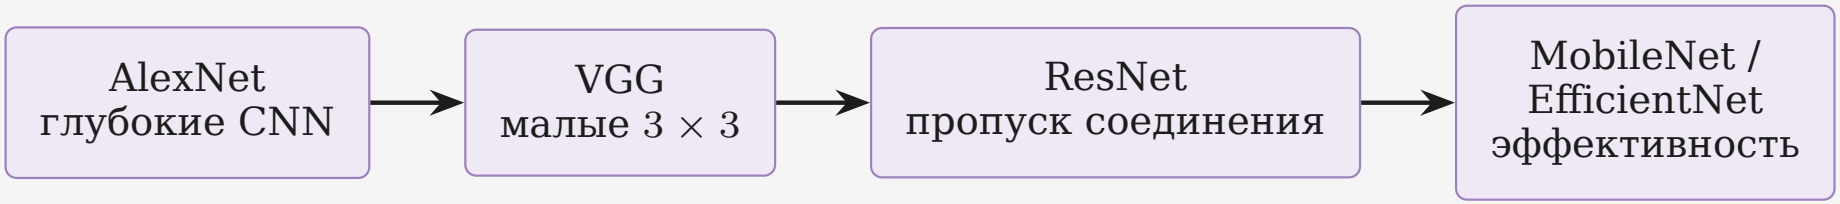
Раздел

Эволюция CNN-архитектур



Полезные предобученные модели

Важнее понять инженерную и методологическую эволюцию CNN, чем запоминать сотни моделей.



Главные вопросы

Как сделать сеть глубже? Как стабилизировать обучение? Как уменьшить вычислительную стоимость? Как получить хорошее качество на ограниченных ресурсах?

VGG как композиция малых свёрток

Идея VGG-подхода — строить глубокую сеть из повторяющихся малых свёрток, чаще всего 3×3.



Интерпретация

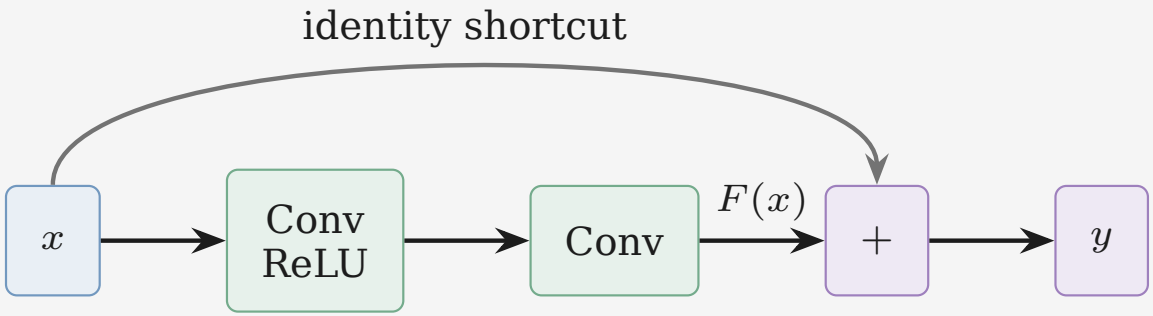
Несколько малых свёрток подряд позволяют увеличить эффективное поле зрения и добавить нелинейности, сохраняя регулярную архитектуру.



ResNet и разносные соединения

С ростом глубины сети обучение становится сложнее. ResNet вводит остаточную связь.

$$y = F(x) + x.$$



Смысл

Слой может учить не полное преобразование, а поправку к входу. Это облегчает обучение глубоких сетей.

EfficientNet и MobileNet

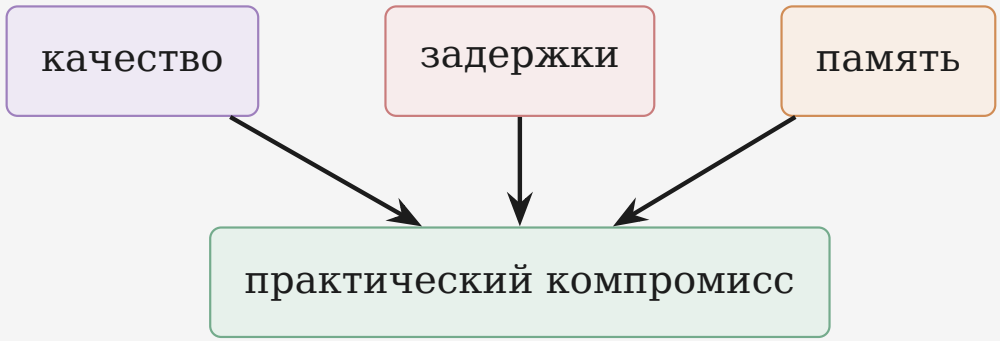
Для практических задач часто важна не только точность, но и стоимость вывода.

MobileNet

Ориентирован на лёгкие модели и ограниченные устройства. Использует эффективные свёрточные блоки.

EfficientNet

Идея сбалансированного масштабирования глубины, ширины и разрешения входа.





Раздел

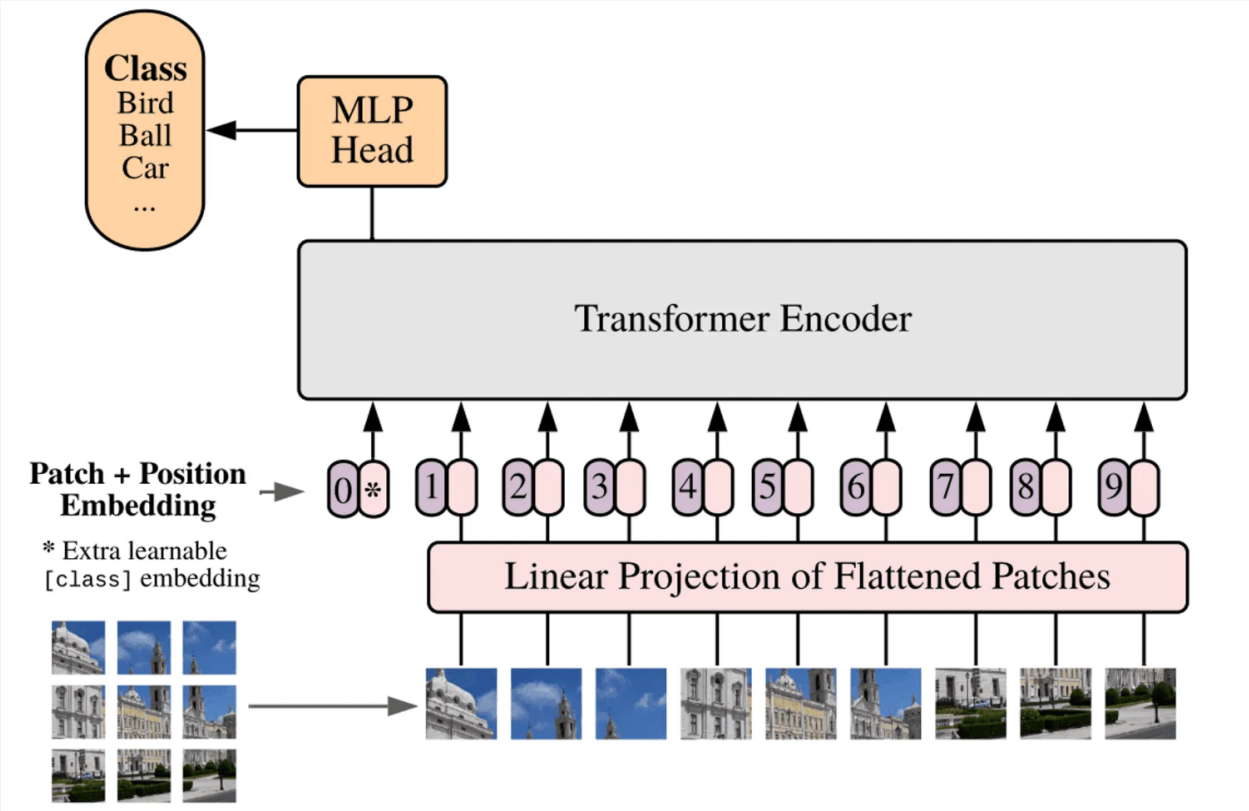
Vision Transformer



Переход от CNN к Transformer

Идея Vision Transformer

Разбить изображение на небольшие фрагменты, превратить каждый фрагмент в вектор и обработать получившуюся последовательность механизмом самовнимания.

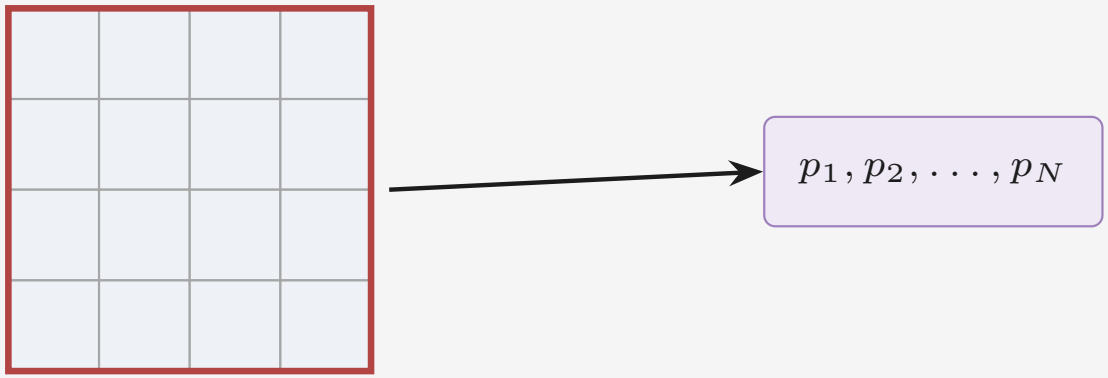


Разбиение на фрагменты

Если изображение имеет размер $H \times W$, а фрагмент имеет размер $P \times P$, то число фрагментов равно

$$N = \frac{H}{P} \cdot \frac{W}{P}$$

при условии делимости размеров.



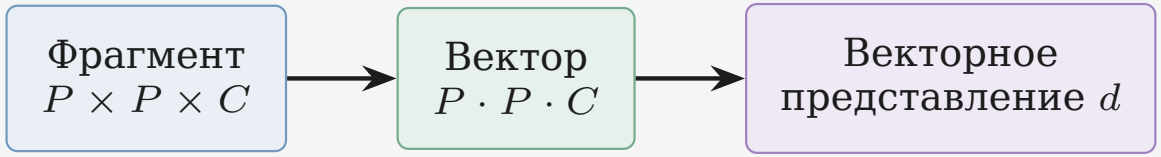
изображение как сетка фрагментов



Векторное представление фрагментов

Каждый фрагмент разворачивается в вектор и линейно проецируется в пространство модели.

$$z_i = E\ \mathrm{vec}(p_i) + b.$$



Аналогия с NLP

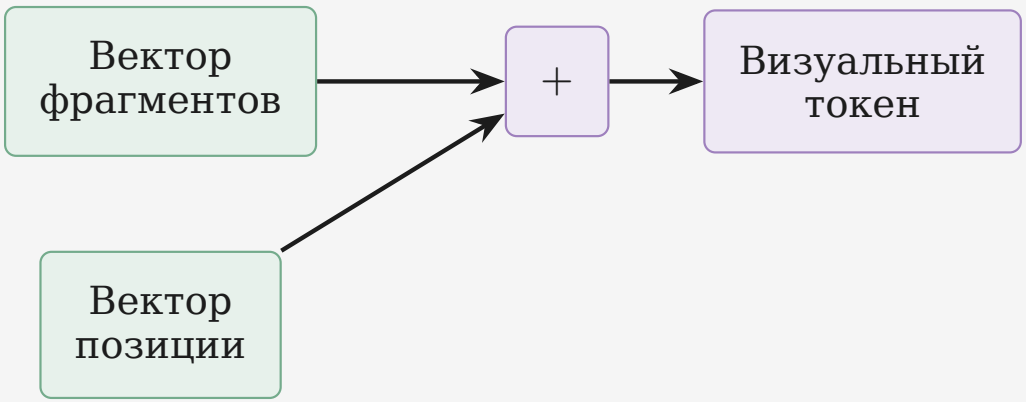
В NLP Transformer получает последовательность токенов. В ViT роль токенов играют векторные представления отдельных фрагментов.



Позиционная информация

Механизм самовнимания сам по себе не знает, где находился фрагмент в исходном изображении. Поэтому к векторам фрагментов добавляют позиционную информацию.

$$\tilde{z}_i = z_i + p_i^{pos}.$$

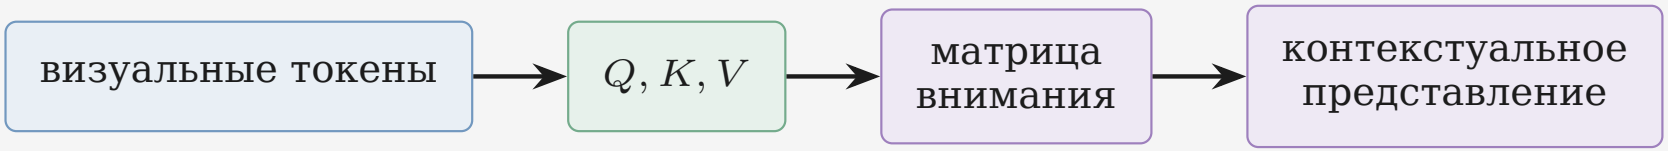


Без позиции модель хуже различает одинаковые фрагменты в разных местах изображения.

Самовнимание над изображением

Механизм внимания остаётся тем же:

$$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V.$$



Интерпретация

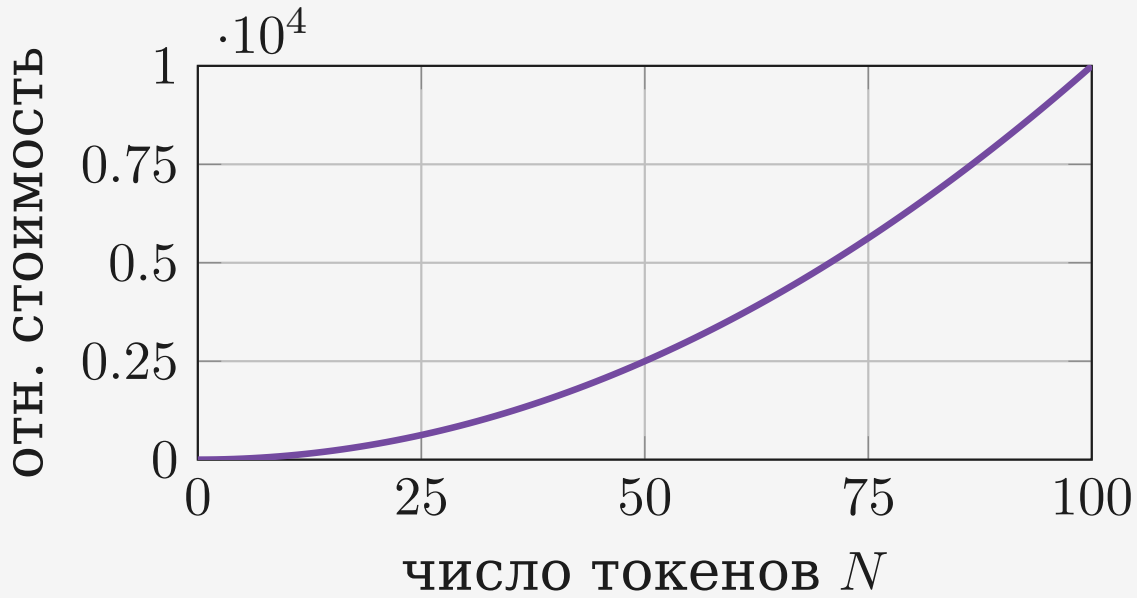
Каждый фрагмент может учитывать информацию от других фрагментов. Это даёт глобальное взаимодействие, в отличие от локального характера первых CNN-слоёв.



Цена внимания

Если число визуальных токенов равно N, то матрица внимания имеет размер $N \times N$.

$$Cost_{attention} \sim O(N^2).$$



Уменьшение размера фрагмента увеличивает число токенов и резко повышает стоимость внимания.

CNN и ViT. Различие архитектур

CNN

- локальность;
- разделение весов;
- естественная работа с трансляциями;
- хорошо работает при умеренных объёмах данных.

Vision Transformer

- глобальные связи между фрагментами;
- меньше встроенных предположений о локальности;
- часто требует больших датасетов или сильного предобучения;
- естественно связывается с мультимодальными моделями.



Раздел

Мультимодальные модели



Мультимодальность

Современные модели всё чаще работают не только с одним типом данных, а с несколькими модальностями.

Текст + Изображение $\rightsquigarrow$ совместное представление.

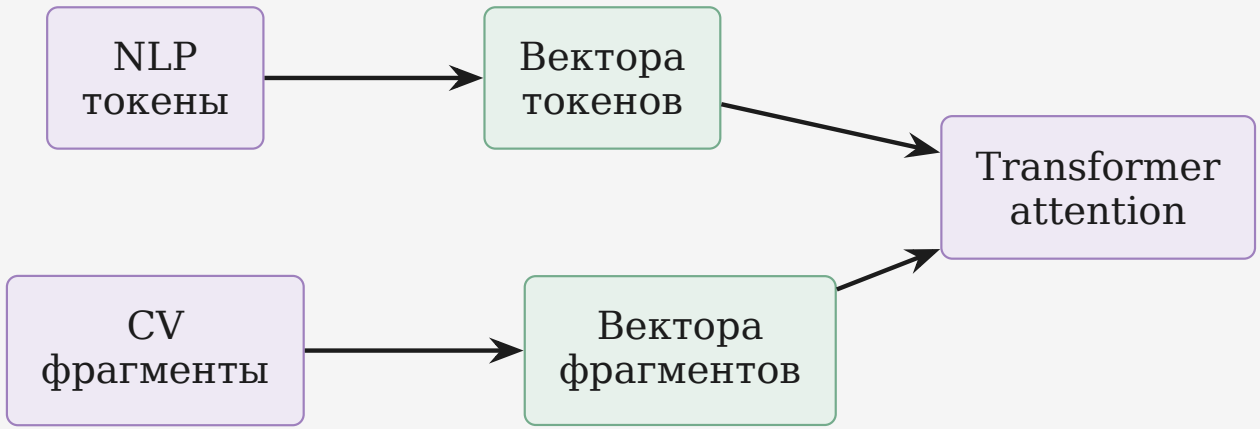


Примеры задач

Поиск изображений по текстовому запросу, генерация описаний, визуальные вопросно-ответные системы, анализ документов с изображениями и текстом.

Связь с предыдущей лекцией

Лекция о Transformer и LLM дала нам язык для понимания механизма внимания, векторных представлений, предобучения и дообучения. В компьютерном зрении эти понятия возвращаются в новой форме.



Различаются входные объекты, но сохраняется идея обучаемого представления.



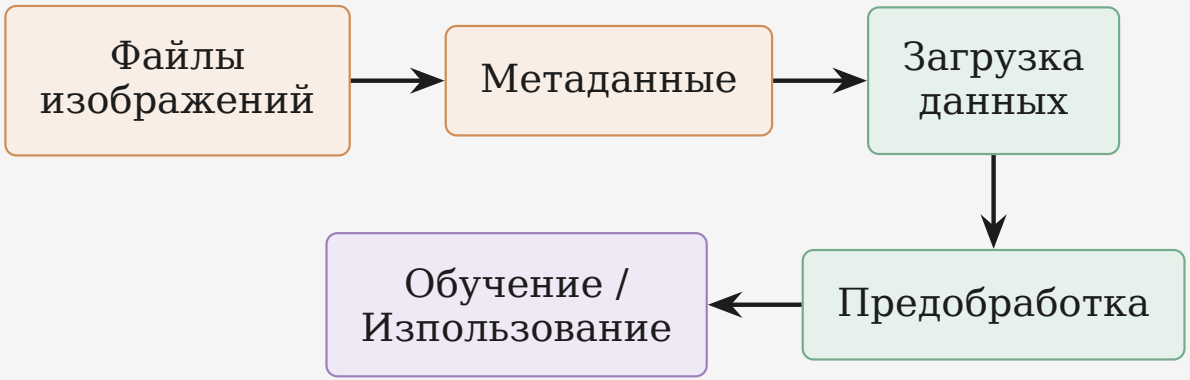
Раздел

Большие коллекции изображений



Почему большие коллекции изображений — это инженерная проблема

Модельная часть — только один компонент CV-системы. При большом масштабе критичными становятся чтение данных, декодирование, предобработка, метаданные и воспроизводимость.



Проблема масштаба

Даже если модель помещается в память, поток обработки может быть ограничен скоростью чтения файлов и декодирования изображений.

Хранение миллионов файлов

Большая коллекция изображений часто состоит из огромного числа относительно небольших файлов.

Типичные проблемы

- файловая система плохо работает с миллионами мелких файлов в одной директории;
- нужно хранить пути, классы, аннотации, размеры, версии и признаки качества;
- требуется быстрый доступ для обучения и воспроизводимое разделение train/validation/test;
- желательно отделять бинарные данные от табличных метаданных.





Метаданные изображений

Метаданные превращают набор файлов в аналитический датасет.

Поле	Пример	Назначение
image_id	000123	уникальный идентификатор
path	/data/img/000123.jpg	физическое расположение
label	defect	целевой класс
width, height	1024, 768	контроль размера
split	train	воспроизводимое разделение
version	v3	версия датасета
source	camera_7	происхождение данных

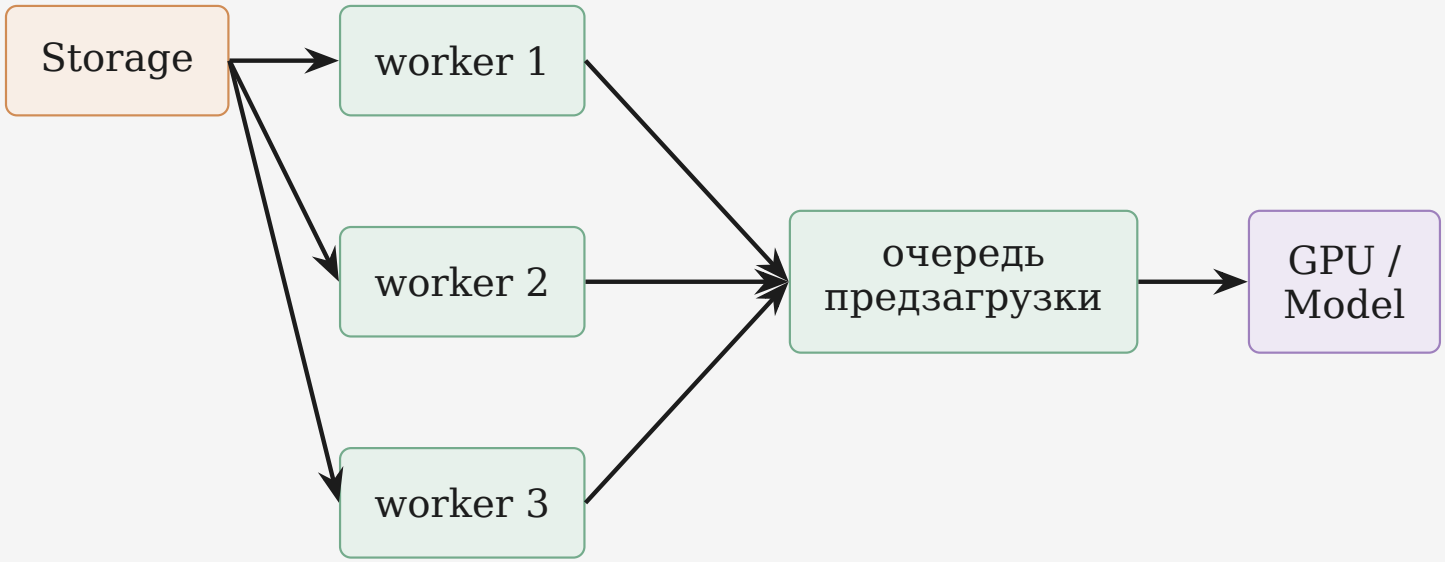
Архитектурное правило

Бинарное изображение удобно хранить в файловом или объектном хранилище, а метаданные — в табличной системе, например PostgreSQL.



Параллельное чтение

В пайплайне обучения вычислитель не должен простаивать в ожидании данных.

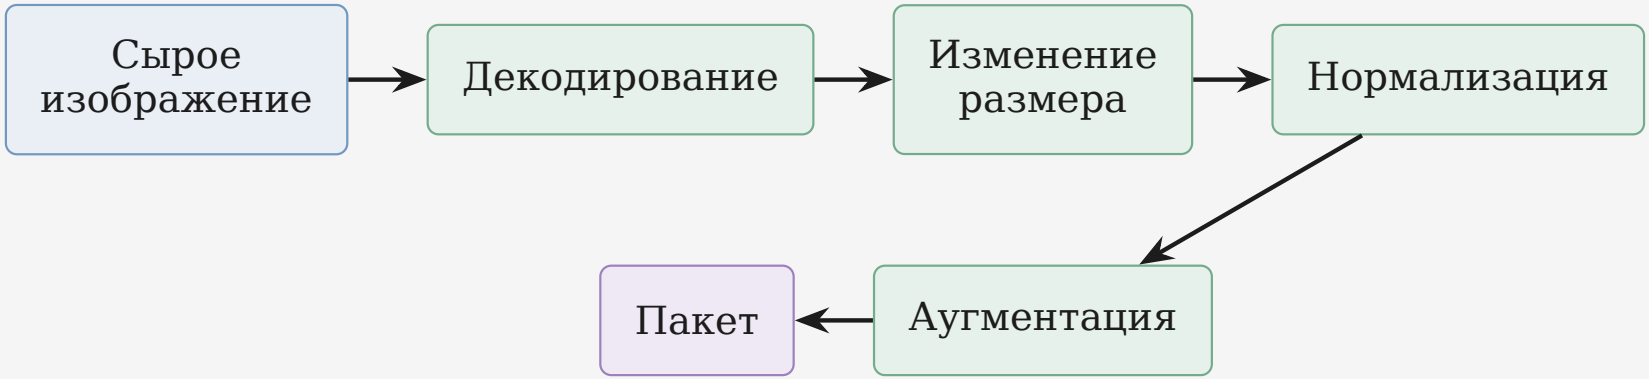


Смысл

Параллельные работники заранее читают, декодируют и подготавливают изображения, чтобы модель непрерывно получала пакеты изображений.

Предобработка

Перед подачей в модель изображение обычно проходит цепочку преобразований.



Примеры операций

Изменение размера, обрезка, нормализация каналов, случайные повороты, отражения, цветовые искажения, преобразование в тензор для программной обработки.



Аугментация

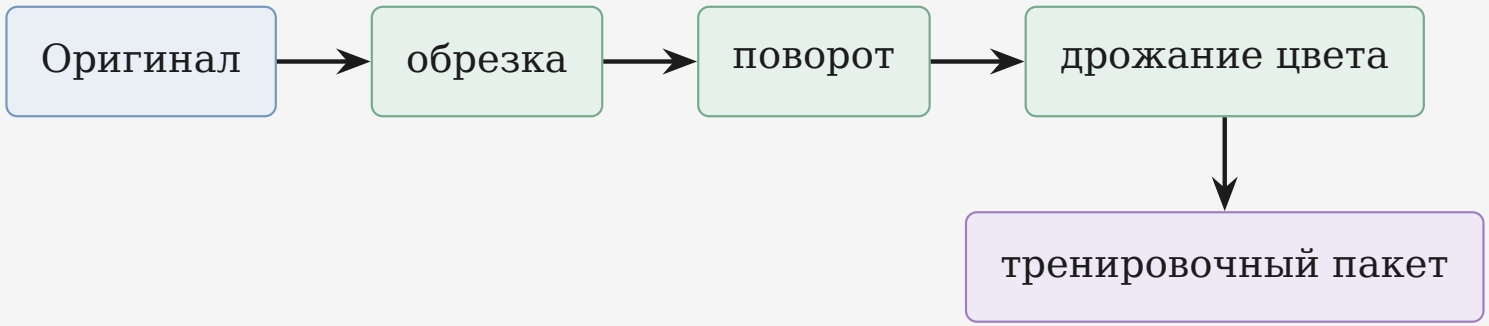
Аугментация данных создаёт изменённые варианты изображения, сохраняя целевой класс.

Зачем

- уменьшить переобучение;
- повысить устойчивость к сдвигам и шумам;
- имитировать разнообразие реального мира.

Осторожно

Не всякое преобразование корректно. Например, отражение медицинского снимка или дорожного знака может изменить смысл.



Формирование пакета

Для пакета важно не только выбрать N объектов, но и привести их к совместимому формату.

Требования к пакету

- одинаковая форма тензора внутри пакета;
- единый тип данных, например FP32 или FP16;
- нормализация каналов;
- корректные метки или маски;
- контролируемый баланс классов при сильной несбалансированности.

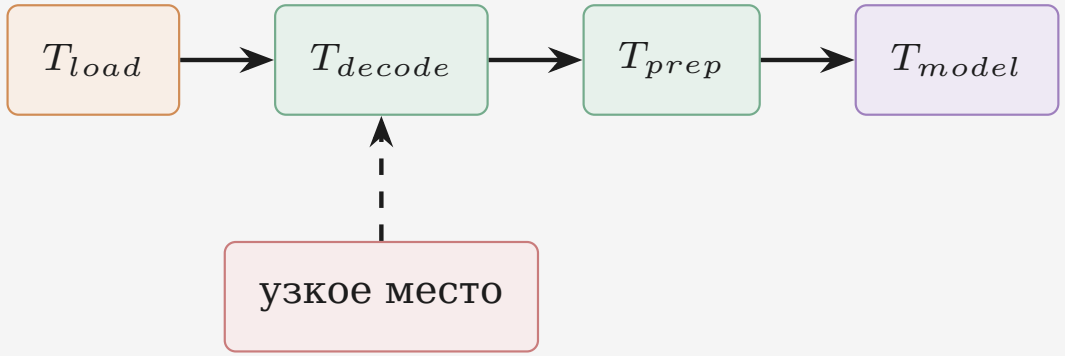
$$\{I_1, \ldots, I_N\} \to X \in \mathbb{R}^{N \times C \times H \times W}.$$



Грубая модель пропускной способности

Время одного шага обучения можно грубо представить как максимум из времени подготовки данных и времени вычисления модели:

$$T_{step} \approx \max(T_{load} + T_{decode} + T_{prep},\ T_{model}).$$

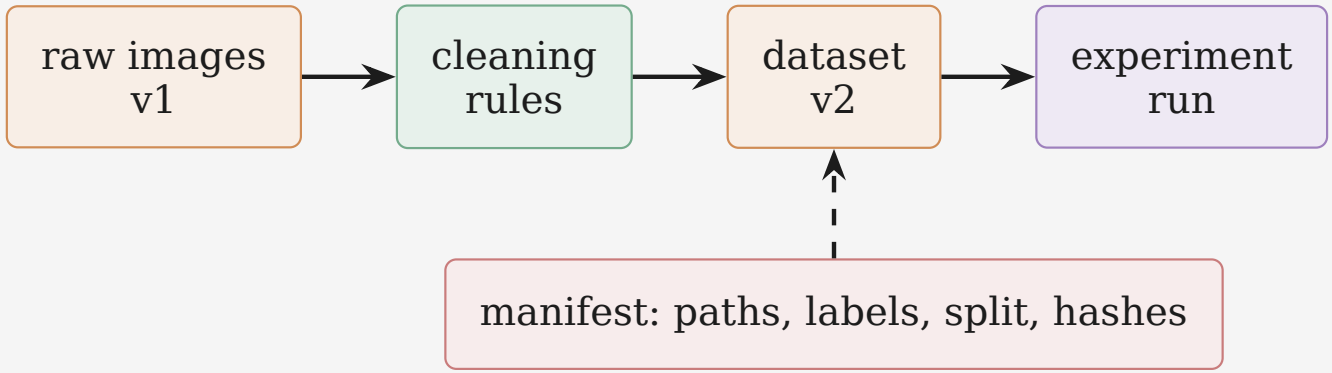


Вывод

При плохом пайплайне обработки данных дорогая GPU может простаивать, потому что данные поступают слишком медленно.

Версионирование датасета

Воспроизводимость CV-эксперимента требует фиксировать не только код модели, но и версию данных.



Практический принцип

Если невозможно восстановить точный состав train/validation/test, то качество модели нельзя строго сравнивать между запусками.

Связь с Spark и PostgreSQL

В практической архитектуре изображения и метаданные удобно разделять.



Пример анализа метаданных

Распределение классов, размеры изображений, доля повреждённых файлов, источники данных, качество разметки, баланс train/validation/test.

Раздел

Качество моделей и ошибки



Метрики классификации

Для простой классификации применяются уже знакомые метрики.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}, \qquad Precision = \frac{TP}{TP + FP},$$

$$Recall = \frac{TP}{TP + FN}, \qquad F_1 = 2\frac{Precision \cdot Recall}{Precision + Recall}.$$

Почему accuracy может обманывать

Если один класс сильно доминирует, модель может иметь высокую accuracy, но почти не находить редкий важный класс.



Метрики детекции и сегментации

Для локализации объектов нужны другие показатели.

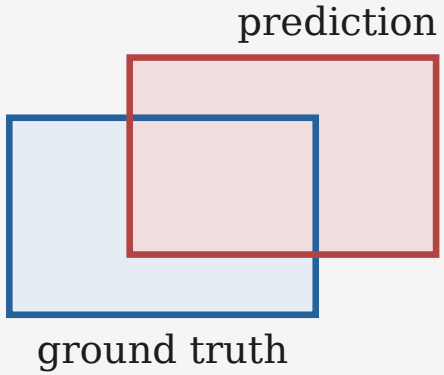
IoU

Intersection over Union измеряет пересечение предсказанной и истинной области:

$$IoU = \frac{|A \cap B|}{|A \cup B|}.$$

mAP

Mean Average Precision агрегирует качество детекции по классам и порогам совпадения. Часто используется в object detection.



Анализ ошибок

Качество CV-модели нельзя оценивать только одной цифрой. Нужно смотреть на структуру ошибок.

Типичные вопросы анализа

- какие классы чаще всего путаются;
- возникают ли ошибки на тёмных, размытых или малых объектах;
- есть ли сдвиг между train и production-данными;
- достаточно ли качественная разметка;
- не учится ли модель на фоновых артефактах.

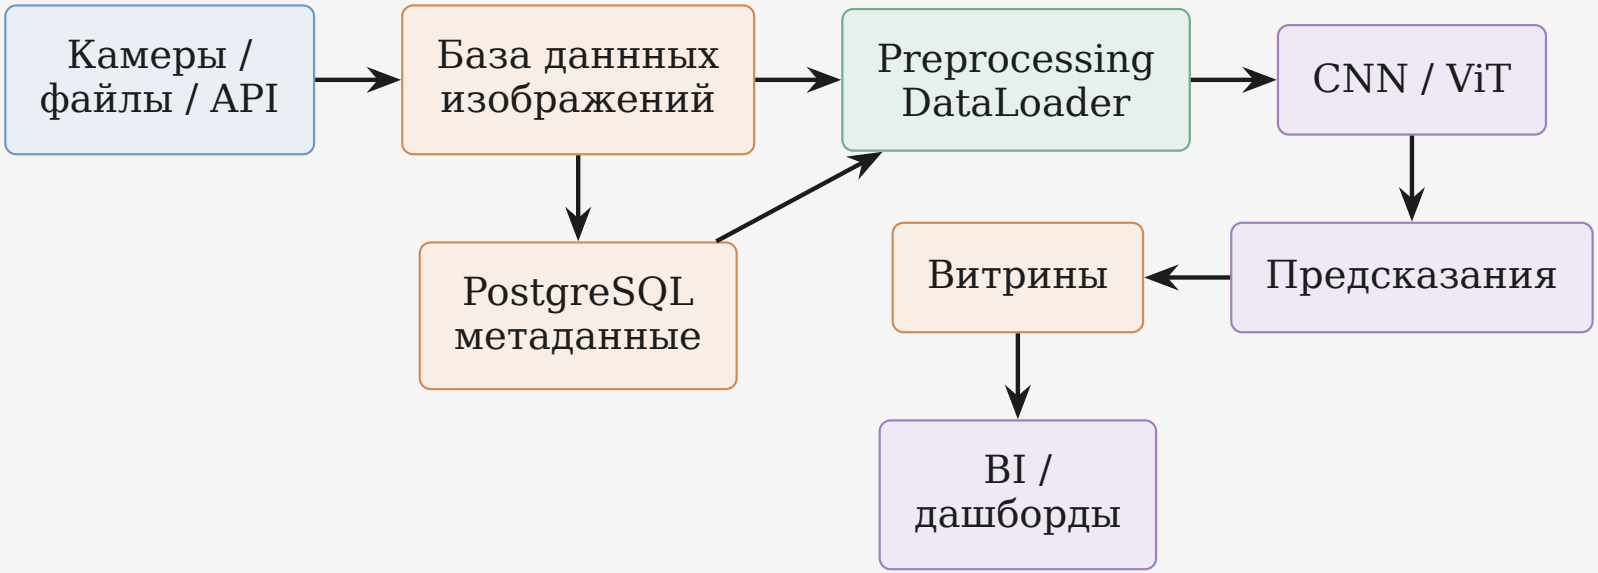


Раздел

Итоговая архитектура



End-to-end CV pipeline



Главная мысль

Computer Vision в промышленной системе — это не только модель, но и полный контур данных, включающий хранение, метаданные, предобработку, обучение, применение, контроль качества и мониторинг.

Контрольные вопросы

1. Чем файл изображения отличается от тензора изображения?
2. Почему RGB-изображение имеет три канала?
3. Почему полносвязная сеть не является хорошей базовой моделью для больших изображений?
4. Что означает локальная связность в CNN?
5. Как записывается операция свёртки?
6. Что такое feature map?
7. Как stride и padding влияют на размер выхода?
8. Зачем нужен pooling?



Контрольные вопросы

9. Чем classification отличается от detection и segmentation?
10. В чём различие feature extractor и fine-tuning?
11. Как residual connection помогает обучать глубокие сети?
12. Почему Vision Transformer разбивает изображение на patches?
13. Почему attention имеет квадратичную стоимость по числу tokens?
14. Какие инженерные проблемы возникают при миллионах изображений?
15. Зачем отделять метаданные от бинарных файлов изображений?



Спасибо за внимание!

