



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ

по дисциплине «Технологии и инструментарий анализа больших данных»

Практическая работа №3

Распределенная модель обработки данных

Студент
группы

ИНБО-12-23, Албахтин И.В.

(подпись)

Преподаватель

Воронцов Ю.А.

(подпись)

Москва 2026 г.

1 Цель и постановка задачи

Цель работы — выполнить распределённую табличную обработку в PySpark: подготовить источник SQLite, задать схемы, исследовать пропуски, построить агрегаты и JOIN, сопоставить Spark SQL с DataFrame API и проверить экспорт. Учебная часть выполнена на Olist, самостоятельная — на продажах КОМУС.

Итогом стали аналитическая витрина Olist из 74 категорий и витрина КОМУС по товарным группам. Результаты получены полным последовательным запуском notebook в новом ядре; исходные таблицы не изменялись.

2 Окружение и источники

Результаты приведены в таблице 1.

Таблица 1 – Паспорт стенда

Параметр	Фактическое значение
Среда	VirtualBox, Ubuntu 22.04.5
Ресурсы VM	2 vCPU, 4 ГБ ОЗУ, диск 40 ГБ
Процессор хоста	AMD Ryzen 7 9700X
Python	3.10.12
Java	openjdk version "17.0.20.1" 2026-08-18
Spark	3.5.7
Master и parallelism	local[*], 2
Shuffle partitions	8
AQE	true

Python 3.10.12 используется из изолированного окружения Ubuntu. Методичка рекомендует Python 3.11, но выбранная версия совместима с Spark 3.5.7 и JDK 17. Local[*] использует два доступных виртуальных ядра и не является физическим кластером.

Ecommerce.sqlite восстановлена из CSV Olist, использованных во второй практике, поскольку исходный файл SQLite не был передан. Восстановление и staging выполняются отдельным скриптом. Фактическая версия содержит 100 000 отзывов, тогда как в примере методички указано 97 621; эта разница не

скрывается и не исправляется под ожидаемые числа. Справочник категорий восстановлен до исходных 71 записей.

Результаты приведены в таблице 2.

Таблица 2 – Выгруженные учебные таблицы

Таблица	Число строк
orders	99 441
order_items	112 650
products	32 951
customers	99 441
order_payments	103 886
order_reviews	100 000
product_category_name_translation	71

Spark не читает SQLite как штатный файловый формат. Модуль `sqlite3` и `Pandas` выгружают таблицы частями по 50 000 строк; последующая обработка производится в Spark. Данные КОМУС получены из предоставленного архива «Транзакции КОМУС.zip». Клиентские реквизиты, адреса и номера машин исключены ещё при подготовке входа. Архивы `transactions` и `northwind_small` не использовались: выбранный набор КОМУС удовлетворяет требованиям самостоятельной части.

3 Схемы и преобразования

`Orders` при чтении CSV имеет строковые столбцы. Для `order_items` задан `StructType`: `order_item_id` — `integer`, `price` и `freight_value` — `double`, идентификаторы — `string`. Автоматический вывод схемы дополнительно определяет `shipping_limit_date` как `timestamp`, поэтому схемы не обязаны полностью совпадать. Пять временных полей `orders` преобразованы функцией `to_timestamp`.

```
items_schema = StructType([
    StructField("order_id", StringType(), True),
    StructField("order_item_id", IntegerType(), True),
    StructField("product_id", StringType(), True),
    StructField("seller_id", StringType(), True),
    StructField("shipping_limit_date", StringType(), True),
    StructField("price", DoubleType(), True),
    StructField("freight_value", DoubleType(), True)
])
```

Применены select, filter, withColumn, drop, dropDuplicates и orderBy. Для позиций price ≥ 500 вычислена цена с доставкой gross_item_value; условию удовлетворяют 3 239 строк. Это стоимость позиции, а не всего заказа.

Результаты приведены в таблице 3.

Таблица 3 – Самые дорогие позиции с доставкой

Позиция	Цена	Доставка	Итого
1	6 735,00	194,31	6 929,31
1	6 729,00	193,21	6 922,21
1	6 499,00	227,66	6 726,66
1	4 799,00	151,34	4 950,34
1	4 690,00	74,34	4 764,34

4 Пропуски и предметная интерпретация

Результаты приведены в таблице 4.

Таблица 4 – Пропуски временных полей orders

Поле	Null
order_purchase_timestamp	0
order_approved_at	160
order_delivered_carrier_date	1783
order_delivered_customer_date	2965
order_estimated_delivery_date	0

Фактическая дата доставки отсутствует в 2 965 заказах. По статусам это 1 107 shipped, 619 canceled, 609 unavailable, 314 invoiced, 301 processing, 8 delivered, 5 created и 2 approved. Дата не заполнена вымышленным значением и не служит причиной удаления незавершённых заказов.

Из 96 478 заказов delivered дата известна у 96 470. Просрочено 7 826 заказов, или 8,11% известной выборки. В products у 610 товаров отсутствует категория; она обозначена unknown, чтобы сохранить позиции при соединении.

На рисунке 1 показан результат выполнения на стенде.

```

TIABD PRACTICE 3 I QUALITY
order_purchase_timestamp      : 0
order_approved_at            : 160
order_delivered_carrier_date   : 1783
order_delivered_customer_date  : 2965
order_estimated_delivery_date  : 0
Delivery: {'delivered': 96478, 'known': 96470, 'late': 7826}
Missing categories: 610
JOIN: {'before': 112650, 'after': 112650, 'unknown': 1603}
student@tiabd-pr2:~/spark-lab$ _

```

Рисунок 1 – Проверка пропусков и сохранения строк в консоли Ubuntu

5 Агрегации и соединения

Результаты приведены в таблице 5.

Таблица 5 – Статусы заказов

Статус	Заказы
delivered	96 478
shipped	1 107
canceled	625
unavailable	609
invoiced	314
processing	301
created	5
approved	2

Результаты приведены в таблице 6.

Таблица 6 – Агрегаты платёжных строк

Способ оплаты	Строки	Сумма	Среднее
credit_card	76 795	12 542 084,19	163,32
boleto	19 784	2 869 361,27	145,03
voucher	5 775	379 436,87	65,70
debit_card	1 529	217 989,79	142,57
not_defined	3	0,00	0,00

Платежи credit_card преобладают по числу строк и сумме. COUNT(*) в order_payments нельзя интерпретировать как число заказов: один заказ может иметь несколько платежей.

LEFT JOIN order_items → products → translations сохранил 112 650 из 112 650 позиций; 1 603 позиций имеют unknown. Категория выбирается через coalesce: английский перевод, исходное название, затем unknown.

Результаты приведены в таблице 7.

Таблица 7 – Пять штатов с высокой долей просрочки

Штат	Доставлено	Просрочено	Доля %
AL	397	95	23,93
MA	717	141	19,67
PI	476	76	15,97
CE	1279	196	15,32
SE	335	51	15,22

AL имеет 23,93% просрочки при 397 известных доставках. Доля сравнивается вместе с размером группы; сама таблица не доказывает причинное влияние штата на доставку.

6 Spark SQL и сохранение витрины

```
sales.createOrReplaceTempView("sales")
SELECT category, COUNT(*) AS items,
      COUNT(DISTINCT order_id) AS orders,
      ROUND(SUM(price), 2) AS revenue,
      ROUND(AVG(price), 2) AS avg_price
FROM sales
GROUP BY category
ORDER BY revenue DESC
```

Результаты приведены в таблице 8.

Таблица 8 – Топ категорий Olist по сумме price

Категория	Позиции	Сумма price	Средняя цена
health_beauty	9 670	1 258 681,34	130,16
watches_gifts	5 991	1 205 005,68	201,14
bed_bath_table	11 115	1 036 988,68	93,30
sports_leisure	8 641	988 048,97	114,34
computers_accessories	7 827	911 954,32	116,51

Двусторонний экспорт All между полными результатами SQL и DataFrame API дал 0 различий. Витрина содержит 74 группы и записана в Parquet и CSV; для маленького CSV использован coalesce(1). После чтения Parquet совпали

число строк, имена и типы полей. Признак nullable стал true для ранее гарантированно заполненных агрегатов, поэтому полное равенство StructType отдельно отмечено как false.

На рисунке 2 показан результат выполнения на стенде.

```
TIABD PRACTICE 3 I OLIST
category            items    revenue
health_beauty       9670    1258681.34
watches_gifts       5991    1205005.68
bed_bath_table      11115   1036988.68
sports_leisure      8641    988048.97
computers_accessories 7827    911954.32
furniture_decor     8334    729762.49
cool_stuff          3796    635290.85
housewares          6964    632248.66
auto                4235    592720.11
garden_tools        4347    485256.46
Export checks: {'rows': 74, 'types_equal': True, 'nullable_equal':
False, 'sql_diff': 0}
student@tiabd-pr2:~/spark-lab$ _
```

Рисунок 2 – Вычисленные категории Olist и проверки экспорта

7 Самостоятельный анализ продаж КОМУС

Основная таблица содержит 865 222 строк и восемь полей: себестоимость, дата, чек, товарный ключ, филиал, количество, сумма покупки и скидка. Справочник содержит 21 163 уникальных ключей товара и признаки бренда и группы. Названия и условия предоставлены в пользовательском архиве; публичная лицензия на исходные строки не заявлена, поэтому в Git сохраняются код, агрегаты и обезличенные результаты, а не исходные транзакции.

Явный StructType фиксирует строковую схему сырого входа. Дата преобразована из dd.ММ.уууу, десятичная запятая заменена точкой перед приведением четырёх числовых полей. Филиал очищен trim, вычислены месяц

покупки и $\text{margin} = \text{amount} - \text{cost}$. Категориальные пропуски справочника маркируются unknown только в соответствующих полях.

Результаты приведены в таблице 9.

Таблица 9 – Пропуски КОМУС после приведения типов

Поле	Null
receipt id	3 934
purchase date	0
amount	0
cost	86 431
product key	0

У 3 934 строк отсутствует номер чека, но продажи сохранены: фиктивный чек не создаётся. У 86 431 строки отсутствует себестоимость; такие строки участвуют в выручке, но их маржа остаётся null. SUM(margin) описывает только строки с известной себестоимостью, а cost_known показывает охват. Фильтр валидной даты и суммы не удалил строки, поскольку оба поля полностью заполнены.

До JOIN: 865 222 строк; LEFT JOIN: 865 222; INNER JOIN: 865 222. Несопоставленных ключей — 0, конфликтующих ключей справочника — 0. Полный охват объясняет одинаковые размеры обоих соединений.

Результаты приведены в таблице 10.

Таблица 10 – Товарные группы КОМУС с высокой выручкой

Группа	Строки	Выручка	Известная маржа
ЗХК	77 998	11 013 671,73	4 970 760,76
Основы-холст на подрамнике-Базовый	6 703	4 407 000,88	2 022 021,65
Бумага-Картон-пенокартон	2 531	2 716 844,79	1 213 973,44
Faber-Castell	10 023	2 632 258,18	1 175 326,88
Подрамники, рамы-Планшеты	3 850	2 550 475,59	1 170 236,14

Результаты приведены в таблице 11.

Таблица 11 – Выручка по филиалам


Филиал	Строки	Выручка
ТЗ-2 (Ленинградское шоссе)	431 372	58 750 803,24
ТЗ-1 (ул.Фадеева)	238 046	44 343 168,32
ТЗ-3 (Курский)	190 730	26 249 055,61
Багетная мастерская	848	1 399 096,07
РС (Распределительный склад)	249	788 679,75
Кафе-1 (ул.Фадеева)	3 977	207 762,35

Выполнены группировки по товарной группе и филиалу. Первая включает count, sum, avg и счётчик известной себестоимости. Два SQL-запроса формируют рейтинг групп и динамику по месяцам; полный рейтинг SQL совпал с DataFrame API по двустороннему exceptAll.

```
SELECT month, COUNT(*) AS lines,  
       ROUND(SUM(amount), 2) AS revenue,  
       ROUND(SUM(discount), 2) AS discount  
FROM komus_sales  
GROUP BY month  
ORDER BY month
```

Итоговая витрина содержит 2 864 товарных групп. Parquet и CSV сохранены в exports. Повторное чтение подтвердило количество строк и типы, изменение nullable зафиксировано отдельно. Расчётная маржа не является чистой прибылью: дополнительные расходы и налоги в источнике отсутствуют.

На рисунке 3 показан результат выполнения на стенде.



```
TIABD PRACTICE 3 I KOMUS  
Rows: 865222 Dimension unique: 21163  
Null counts: {'receipt_id': 3934, 'purchase_date': 0, 'amount': 0,  
             'cost': 86431, 'product_key': 0}  
JOIN counts: {'before': 865222, 'left': 865222, 'inner': 865222, '  
unmatched': 0}  
Output groups: 2864  
Roundtrip types: True  
Branches:  
T3-2 ( Ленинградское шоссе) 431372 58750803.24  
T3-1 ( ул.Фадеева) 238046 44343168.32  
T3-3 (Курский) 190730 26249055.61  
Багетная мастерская 848 1399096.07  
РС (Распределительный склад) 249 788679.75  
Кафе-1 ( ул.Фадеева) 3977 207762.35  
student@tiabd-pr2:~/spark-lab$
```

Рисунок 3 – Реальные проверки данных КОМУС и обоих JOIN в Ubuntu

На рисунке 4 показан результат выполнения на стенде.

Job Id	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
204	count at <unknown>:0 count at <unknown>:0	2026/10/05 03:22:20	3 ms	1/1 (1 skipped)	1/1 (1 skipped)
203	count at <unknown>:0 count at <unknown>:0	2026/10/05 03:22:20	4 ms	1/1	1/1
202	collect at /home/student/spark-lab/lab_helpers.py:21 collect at /home/student/spark-lab/lab_helpers.py:21	2026/10/05 03:22:20	12 ms	1/1 (2 skipped)	1/1 (3 skipped)
201	collect at /home/student/spark-lab/lab_helpers.py:21 collect at /home/student/spark-lab/lab_helpers.py:21	2026/10/05 03:22:20	7 ms	1/1 (1 skipped)	1/1 (2 skipped)
200	collect at /home/student/spark-lab/lab_helpers.py:21 collect at /home/student/spark-lab/lab_helpers.py:21	2026/10/05 03:22:20	5 ms	1/1 (1 skipped)	1/1 (2 skipped)
199	collect at /home/student/spark-lab/lab_helpers.py:21 collect at /home/student/spark-lab/lab_helpers.py:21	2026/10/05 03:22:19	1 s	1/1	2/2
198	collect at /home/student/spark-lab/lab_helpers.py:21 collect at /home/student/spark-lab/lab_helpers.py:21	2026/10/05 03:22:18	11 ms	1/1 (1 skipped)	1/1 (1 skipped)
197	collect at /home/student/spark-lab/lab_helpers.py:21 collect at /home/student/spark-lab/lab_helpers.py:21	2026/10/05 03:22:18	45 ms	1/1	1/1
196	collect at /home/student/spark-lab/lab_helpers.py:21 collect at /home/student/spark-lab/lab_helpers.py:21	2026/10/05 03:22:18	9 ms	1/1 (2 skipped)	1/1 (3 skipped)
195	collect at /home/student/spark-lab/lab_helpers.py:21	2026/10/05	18 ms	1/1 (1 skipped)	1/1 (2 skipped)

Рисунок 4 – Spark UI фактически выполненного приложения третьей практики

8 Выводы и ограничения

1. Явная схема и преобразование timestamp сделали расчёты воспроизводимыми; автоматическая схема CSV не равна контракту данных.
2. Пропуски даты доставки связаны со статусом, поэтому массовое удаление незавершённых заказов исказило бы анализ.
3. LEFT JOIN Olist сохранил 112 650 позиций, включая 1 603 позиции неизвестной категории.
4. Полные результаты Spark SQL и DataFrame API совпали; обе реализации используют один вычислительный движок.

5. Все 865 222 продаж КОМУС сохранены, в том числе продажи без себестоимости; оценка маржи требует отдельного контроля охвата.

6. Справочник КОМУС покрывает все товарные ключи факта, поэтому INNER JOIN и LEFT JOIN дали одинаковое количество строк.

7. Parquet сохранил количество групп и типы полей, но nullable после чтения отличается от исходной схемы агрегатов.

Ограничения: локальная VM не проверяет работу физического кластера; восстановленная версия Olist отличается от SQLite примера по числу отзывов. Для КОМУС неизвестны полные условия формирования выборки, а неполная себестоимость ограничивает интерпретацию маржи. Выводы о сезонности и причинных связях по этим агрегатам не делаются.

Ответы на контрольные вопросы

1. Чем local[*] отличается от физического Spark-кластера и какие элементы программной модели при этом сохраняются?

local[*] использует доступные логические ядра одного узла. В физическом кластере executors размещены на разных узлах; DataFrame, partitions, задачи и ленивое планирование сохраняются в обоих режимах.

2. Каковы роли Driver и Executor в Spark-приложении?

Driver создаёт SparkContext, строит планы и планирует задачи. Executors выполняют задачи и хранят промежуточные данные; в local[*] вычислительная часть работает внутри локальной JVM.

3. Что такое partition и почему число partitions влияет на производительность?

Partition — логическая часть данных, над которой выполняется задача стадии. Малое число разделов ограничивает параллелизм, большое увеличивает расходы на планирование коротких задач.

4. В чём различие transformation и action? Приведите по три примера каждого типа.

Transformation строит план: select, filter, withColumn. Action требует результат: count, collect, запись через write. Одно действие может вызвать несколько внутренних Jobs.

5. Что означает lazy evaluation и почему время выполнения withColumn() без action не отражает стоимость вычислений?

Lazy evaluation откладывает вычисления до action. Создание withColumn формирует выражение, поэтому его время без action не измеряет чтение, вычисление и обмен данными.

6. Почему CSV не содержит строгой аналитической схемы и в каких случаях явный StructType предпочтительнее inferSchema?

CSV хранит текст и разделители, но не строгую схему. StructType полезен при стабильном контракте входа и позволяет избежать отдельного прохода inferSchema; некорректные значения всё равно требуют контроля.

7. Почему строку ISO-даты следует преобразовать в timestamp, даже если лексикографическое сравнение иногда даёт правильный порядок?

Timestamp задаёт временную семантику для datediff, month и сравнения дат. Строковое сравнение зависит от одинакового формата и не проверяет корректность даты.

8. Почему наличие null не означает, что строку нужно удалить? Как это показал пример order_delivered_customer_date?

Null может обозначать незавершённую операцию. В Olist большинство отсутствующих дат доставки относится к shipped, canceled и промежуточным статусам; только восемь пропусков относятся к delivered.

9. Чем `select()` отличается от `filter()`, а `withColumn()` — от простого выбора столбца?

`Select` выбирает столбцы и выражения, `filter` выбирает строки. `WithColumn` добавляет либо заменяет именованный столбец, а выбор существующего столбца не создаёт нового признака.

10. Почему после `JOIN` необходимо сравнивать число строк до и после операции?

Рост количества строк может указывать на неуникальный справочник или связь многие-ко-многим. Уменьшение при `INNER JOIN` может означать потерю фактов без подходящего ключа справа.

11. В чём содержательное различие `INNER JOIN` и `LEFT JOIN` при построении фактовой аналитической витрины?

`INNER JOIN` сохраняет только совпавшие ключи. `LEFT JOIN` сохраняет все левые факты и делает отсутствие справочной записи измеримым через `null`; выбор определяется целью витрины.

12. Почему `COUNT(*)` и `COUNT(DISTINCT order_id)` дают разные бизнес-смыслы для `order_items`?

`COUNT(*)` считает позиции заказа, `COUNT(DISTINCT order_id)` — уникальные заказы. Несколько позиций одного заказа дают разный результат этих двух агрегатов.

13. Как связаны `Spark SQL` и `DataFrame API`? Являются ли они разными вычислительными движками?

Оба интерфейса используют `Spark SQL` и `Catalyst`. `SQL` задаёт декларативный текст запроса, `DataFrame API` строит эквивалентные выражения; это не два независимых движка.

14. Почему Spark записывает DataFrame в каталог с part-файлами, а не обязательно в один файл?

Каждая выходная задача записывает свой part-файл. Каталог соответствует распределённой записи и включает служебные файлы, например _SUCCESS.

15. Почему coalesce(1) допустим для маленькой 74-строчной витрины, но является плохой общей стратегией записи больших данных?

Для 74 строк потеря параллелизма незначительна и один CSV удобен. Для большого факта coalesce(1) создаёт единственную задачу записи и узкое место.

16. Какие преимущества Parquet даёт последующим Spark-задачам по сравнению с CSV?

Parquet хранит типы, поддерживает колоночное чтение, сжатие и проталкивание фильтров. CSV требует восстановления типов; при чтении Parquet nullable может быть true даже при сохранении имён и типов полей.

Источники

1. Практическая работа №3. Распределенная модель обработки данных. Предоставленная методичка.
2. Транзакции КОМУС.zip. Предоставленный учебный архив; SHA-256 зафиксирован в source_manifest.json.
3. Apache Spark 3.5.7. Installation.
https://spark.apache.org/docs/3.5.7/api/python/getting_started/install.html
4. Таблицы Olist из второй практики; версия и количество строк зафиксированы в source_manifest.json.