

Лекция 1. Большие данные и современные архитектуры аналитических систем

Технологии и инструментарий анализа больших данных

Курс ТИАБД



Раздел

Введение



Тема первой лекции

Посмотрим на карту дисциплины от источников данных до аналитических витрин, моделей машинного обучения, BI-инструментов и мониторинга инфраструктуры.


Важные вопросы на обсуждении

- почему традиционная обработка данных перестаёт быть достаточной;
- в чем заключаются инженерные признаки Big Data;
- каково назначение основных слоёв аналитической платформы;
- по какой логике выстраивать связь между программными компонентами обработки и хранения данных

Отдельные технологии курса будут изучаться позже, но уже сейчас нужно понимать их место в общей системе.



Логика всего курса



Современная аналитическая система — это не одна программа, а цепочка компонентов, обеспечивающих сбор, хранение, обработку, моделирование, визуализацию и контроль состояния данных и инфраструктуры.



Главный вопрос лекции

Проблемная постановка

Почему нельзя просто взять одну базу данных, один сервер, один Python-скрипт и обработать все данные привычным способом?

Ответ связан не только с объёмом данных. Ограничения возникают одновременно по нескольким измерениям:

- данные могут не помещаться в память одного узла;
- время обработки может превышать допустимое бизнесом время;
- данные могут поступать непрерывным потоком;
- структура данных может быть неоднородной;
- качество данных может быть нестабильным;
- ценность данных возникает только после построения аналитического процесса.

Именно поэтому Big Data — это не «очень большой файл», а инженерная ситуация, в которой прежняя архитектура перестаёт удовлетворять требованиям задачи.



Раздел

Данные как ресурс информационной системы



Данные как производственный ресурс

Тезис. В современной организации данные выступают не побочным продуктом работы информационных систем, а самостоятельным ресурсом управления.

Примеры управленческих вопросов:


- какие товары чаще возвращаются и почему;
- какие клиенты склонны уходить;
- где возникают задержки доставки;
- какие отзывы имеют негативную тональность;
- какие сервисы работают нестабильно;
- какие события предшествуют сбою или мошеннической операции.

Определение

Data-driven system — информационная система, в которой решения, автоматические действия и управленческие выводы систематически опираются на данные, метрики и модели.



Источники данных



Уже на уровне источников видно, что данные различаются по скорости появления, формату, уровню достоверности и способу дальнейшего анализа.



Пример. интернет-магазин как источник Big Data

В учебном курсе удобно мыслить сквозным примером интернет-магазина.

Операционные данные:

- 1 клиенты;
- 2 заказы;
- 3 позиции заказов;
- 4 платежи;
- 5 продавцы;
- 6 товары;
- 7 доставки.

Аналитические данные:


- 1 отзывы и оценки;
- 2 временные ряды продаж;
- 3 поведение пользователей;
- 4 признаки оттока;
- 5 метрики качества сервиса;
- 6 логи работы приложений.

Тезис. Одна и та же предметная область одновременно порождает структурированные, полуструктурированные и неструктурированные данные.



От данных к аналитическому циклу

Смехатично аналитический процесс строится циклическим образом:



Определение. Жизненный цикл аналитики данных — повторяющийся процесс, в котором данные собираются, сохраняются, преобразуются, анализируются и возвращаются в систему управления в форме решений.



Раздел

Что такое Big Data



Некорректное бытовое определение

Часто Big Data определяют как «данные большого объёма». Это интуитивно понятно, но методологически недостаточно.

Проблемы такого определения:

- один и тот же объём может быть малым для кластера и большим для ноутбука;
- объём не отражает скорость поступления данных;
- объём не описывает разнообразие форматов;
- объём не учитывает требования к задержке обработки;
- объём не говорит о ценности результата.

Рабочая формулировка

Данные становятся **большими** относительно ресурсов, архитектуры и временных требований конкретной системы обработки.



Инженерное определение Big Data

Пусть V_{data} — объём данных, M_{node} — доступная память одного вычислительного узла, $T_{processing}$ — время обработки, $T_{acceptable}$ — допустимое время получения результата.


Ситуация Big Data возникает, если выполняется хотя бы одно из условий:

$$V_{data} > M_{node}, \quad T_{processing} > T_{acceptable}.$$

Если один узел не справляется по памяти, времени или устойчивости, архитектуру нужно менять.




Big Data как относительное понятие



Тезис. Big Data — это не абсолютный размер файла, а соотношение между данными, вычислительной средой и требованиями к результату.



Шесть V-характеристик Big Data



V-характеристики не являются независимыми «ярлыками». Они задают требования к архитектуре: хранению, обработке, качеству данных, скорости реакции и способу извлечения ценности.



Volume. Объём

Определение

Volume — характеристика, отражающая объём данных, который требуется хранить, передавать и обрабатывать.

Инженерные следствия:

- хранение на одном диске становится рискованным или невозможным;
- полное сканирование данных становится дорогим;
- требуется разбиение данных на части;
- резервное копирование и восстановление усложняются;
- возрастает стоимость чтения и перемещения данных.

$$D = P_1 \cup P_2 \cup \dots \cup P_k.$$

Рост объёма почти всегда приводит к вопросу о разделении данных (partitioning) и распределённом хранении.



Velocity. Скорость

Определение

Velocity — скорость генерации, поступления и обработки данных.

Типовые ситуации:

- поток кликов в web-приложении;
- телеметрия IoT-датчиков;
- банковские транзакции;
- журналы событий микросервисов;
- мониторинговые метрики инфраструктуры.

$$d_1, d_2, \dots, d_t, d_{t+1}, \dots$$


Если данные поступают непрерывно, система должна не только хранить исторический массив, но и реагировать на новые события с контролируемой задержкой.



Variety. Разнообразие

Определение

Variety — неоднородность форматов, структур и семантики данных.



Современный Big Data давно не ограничивается таблицами. Текстовые отзывы, изображения и логи требуют специальных методов хранения и анализа.



Veracity, Value, Variability

Veracity

Достоверность, полнота, согласованность и шум в данных.

Value

Способность данных порождать полезное знание, метрику или решение.


Variability

Изменчивость распределений, схем, поведения пользователей и внешней среды.

Большие данные бесполезны без качества и цели анализа. Ошибка в данных может масштабироваться так же быстро, как и сами данные.



Big Data как совокупность требований



Тезис. Архитектура Big Data выбирается не по моде на технологии, а по совокупности требований, среди которых объём, задержка, пропускная способность, разнообразие, устойчивость и качество.



Раздел

Масштабирование вычислений



Вертикальное масштабирование

Определение

Вертикальное масштабирование — увеличение ресурсов одного узла. Процессоров, оперативной памяти, дисков, сетевых интерфейсов.



Достоинства: простота администрирования, привычная модель программирования.


Ограничения: физический предел оборудования, высокая стоимость, единая точка отказа, невозможность бесконечно сокращать время обработки.



Горизонтальное масштабирование

Определение

Горизонтальное масштабирование — распределение хранения и вычислений между несколькими узлами.



В следствие чего возникают разбиение данных, репликация, распределенная обработка, обработка отказов, сетевые издержки, согласование состояния.




Partitioning. Разбиение данных

Определение

Partitioning — разбиение набора данных на логические или физические части, которые могут храниться и обрабатываться независимо.

$$D = P_1 \cup P_2 \cup \dots \cup P_k, \quad P_i \cap P_j = \emptyset \quad (i \neq j).$$




Разбиение данных (partitioning) – ключевая предпосылка параллелизма, поскольку разные части данных можно обрабатывать одновременно.



Replication. Репликация и отказоустойчивость

Определение

Replication — хранение нескольких копий данных на разных узлах для повышения доступности и устойчивости к отказам.



Распределённые вычисления

Определение

Distributed computing — выполнение задачи несколькими вычислительными узлами, каждый из которых обрабатывает часть данных или часть вычислительного графа.



Ключевая цена распределённости в том что обмен данными между узлами становится существенной частью времени выполнения. Узкое горлышко – сетевой интерфейс.



Почему распределённость не бесплатна

Что выигрываем:

- больше суммарной памяти;
- параллельное чтение;
- параллельные вычисления;
- масштабирование под рост данных;
- устойчивость к отказам.

Что усложняется:

- передача данных по сети;
- синхронизация;
- балансировка нагрузки;
- повторное выполнение задач;
- мониторинг кластера;
- отладка производительности.

Ключевой подход

Распределённая архитектура применяется не потому, что она проще, а потому, что она позволяет решать задачи, не помещающиеся в ограничения одного узла.



Раздел

Типы данных




Структурированные данные

Определение

Структурированные данные — данные с заранее заданной **схемой**: набором таблиц, атрибутов, типов и ограничений.

Примеры:

- таблицы заказов;
- справочник клиентов;
- платежи;
- остатки товаров;
- банковские транзакции.



Структурированные данные хорошо подходят для SQL, транзакций, ограничений целостности и классической аналитики.



Полуструктурированные данные

Определение

Полуструктурированные данные — данные, имеющие внутреннюю организацию, но не обязательно фиксированную табличную схему.

Примеры: JSON, XML, Avro, nested records, события web-аналитики.



Такие данные удобно сначала сохранить, а затем интерпретировать схему при чтении и обработке.



Неструктурированные данные

Определение

Неструктурированные данные — данные, не имеющие табличной структуры и требующие специализированных методов извлечения признаков.

Примеры:

- тексты отзывов;
- PDF-документы;
- изображения товаров;
- видео с камер;
- аудиообращения клиентов.

сырой объект → признаки → модель / метрика.

Неструктурированные данные становятся аналитически полезными только после преобразования в числовое представление.



Сводная классификация типов данных

Тип	Примеры	Хранение	Анализ
Структурированные	Таблицы заказов, платежи	PostgreSQL, DWH	SQL, BI, ML
Полуструктурированные	JSON, XML, события	Data Lake, NoSQL	Spark, schema-on-read
Неструктурированные	Тексты, изображения, видео	Object Storage, Data Lake	NLP, CV, embeddings

Ключевая идея

Современная аналитическая платформа должна поддерживать разные типы данных, потому что бизнес-вопросы редко ограничиваются одной таблицей.



Раздел

OLTP и OLAP



Две разные нагрузки

Определение

OLTP — online transaction processing. Обработка множества коротких транзакций, изменяющих текущее состояние системы.


Определение

OLAP — online analytical processing. Выполнение аналитических запросов по историческим и агрегированным данным.

OLTP и OLAP используют данные одной предметной области, но предъявляют противоположные требования к структуре, скорости и характеру запросов.



OLTP. Система операционной обработки



Характеристики OLTP:

- короткие операции;
- частые изменения данных;
- строгая целостность;
- низкая задержка;
- нормализованная модель.



OLAP. Система аналитической обработки



Характеристики OLAP:

- чтение больших объёмов;
- агрегации и группировки;
- исторические данные;
- денормализация и витрины;
- аналитическая задержка допустима выше, чем в OLTP.



Почему OLAP не стоит выполнять прямо на production OLTP

Если аналитика идёт по OLTP:

- тяжёлые запросы конкурируют с транзакциями;
- падает отзывчивость приложения;
- индексы оптимизируются под разные нагрузки;
- сложнее обеспечивать стабильность;
- опаснее экспериментировать с запросами.

Архитектурное решение:

- выгрузка данных;
- ETL/ELT;
- аналитическое хранилище;
- витрины данных;
- отдельные BI-запросы;
- отдельный контур ML.

Вывод

Операционная и аналитическая нагрузки должны быть архитектурно разведены, даже если используют общую предметную область.



OLTP и OLAP: разводка нагрузки



Принцип разделения: OLTP обслуживает частые короткие транзакции приложения, а ресурсоёмкие аналитические запросы выполняются в отдельном OLAP-контуре. Между контурами передаются *данные*, а не аналитическая нагрузка.



Раздел

Хранилища аналитических данных



Data Warehouse. Хранилище данных

Определение

Data Warehouse — централизованное аналитическое хранилище интегрированных, очищенных и историзованных данных, оптимизированное для отчётности и аналитических запросов.

Типовые свойства:

- строгая схема;
- контролируемое качество данных;
- историчность;
- поддержка аналитических витрин;
- SQL-ориентированный доступ.

DWH удобно там, где важны управленческие показатели, согласованные справочники и повторяемая отчётность.



Data Lake. Озеро данных

Определение

Data Lake — хранилище сырых или слабо обработанных данных разных форматов, рассчитанное на последующую интерпретацию и обработку.

Типовые свойства:

- хранение «как есть»;
- поддержка и работа с файлами разных форматов (тексты, JSON, изображения, логи);
- схема на чтение (schema-on-read) каждая под свою задачу;
- использование Spark и других вычислительных движков.

Риск

Без каталогизации, контроля качества и правил доступа Data Lake превращается в «data swamp» — непонятное и плохо управляемое болото данных.



Data Mart. Витрина данных

Определение

Data Mart — предметно-ориентированная аналитическая витрина данных, подготовленная для конкретного класса пользователей, отчётов или моделей.

Примеры витрин:

- продажи по дням, регионам и категориям;
- клиентская активность;
- качество доставки;
- витрина признаков для ML-модели;
- витрина отзывов для NLP-аналитики.


DWH / Data Lake → Data Mart → BI / ML.



Lakehouse

Определение

Lakehouse — архитектурный подход, объединяющий гибкость Data Lake и управляемость Data Warehouse.



Современная платформа стремится хранить разные данные, но не отказываться от транзакционности, каталогизации и качества.



Сравнение хранилищ

Подход	Сильная сторона	Ограничение	Типовая роль
DWH	качество, схема, отчётность	меньшая гибкость к сырым данным	корпоративная аналитика
Data Lake	любые форматы, дешёвое хранение	риск хаоса без governance	сырой слой данных
Data Mart	удобство для конкретной задачи	зависит от источника	BI и ML
Lakehouse	попытка объединить lake и DWH	сложнее архитектурно	современная платформа

Эти понятия не конкурируют напрямую и в зрелой системе они часто используются совместно.



Раздел

Пакетная и потоковая обработка данных



Batch processing. Пакетная обработка


Определение

Batch processing — пакетная обработка конечного набора данных, накопленного за некоторый период.

$$D = \{d_1, d_2, \dots, d_n\} \rightarrow processing \rightarrow result.$$

Примеры:

- ежедневный отчёт по продажам;
- ночная пересборка витрины данных;
- обучение ML-модели;
- расчёт клиентских сегментов.



Batch-схема



Batch-подход хорошо подходит для задач, где допустимо дождаться накопления данных и затем обработать их крупной порцией.



Stream processing. Потокковая обработка

Определение

Stream processing — непрерывная обработка событий, поступающих во времени.


$$d_1, d_2, \dots, d_t \rightarrow \text{continuous processing} \rightarrow \text{state}(t).$$

Примеры:

- выявление мошенничества;
- мониторинг инфраструктуры;
- реакция на события IoT;
- персонализация в реальном времени;
- обнаружение аномалий в логах.



Streaming-схема



В потоковой обработке важны не только данные, но и время. Задержка реакции становится частью требований к системе.



Различия пакетной и потоковой обработки данных

Критерий	Batch	Streaming
Вход	конечный набор	непрерывный поток
Время обработки	по расписанию или по запросу	постоянно
Тип результата	отчёт, витрина, модель	состояние, alert, онлайн-метрика
Сложность	проще контролировать	сложнее из-за времени и состояния
Пример	ночной расчёт продаж	fraud detection в момент транзакции

Вывод. Архитектура выбирается исходя из допустимой задержки между событием и реакцией системы.



Раздел


ETL и ELT



ETL

Определение

ETL — Extract, Transform, Load. Извлечение данных из источников, преобразование во внешнем процессе и загрузка в целевое хранилище.



ETL традиционно удобен для хранилищ со строгой схемой, где данные перед загрузкой должны быть приведены к согласованному виду.



ELT

Определение


ELT — Extract, Load, Transform. Сначала извлекаем и загружаем данные в аналитическую среду, затем преобразуем их средствами этой среды.



ELT распространился потому, что современные аналитические платформы сами обладают мощными вычислительными возможностями.



ETL против ELT



Практический вывод

ETL чаще связан с предварительным контролем и строгой схемой. ELT чаще связан с сохранением сырых данных и последующей гибкой аналитикой.




Раздел

Современный поток Big Data



Центральная схема курса



Дальнейшие лекции курса последовательно раскрывают отдельные слои этой схемы.



Слой источников и извлечение

Определение

Ingestion — процесс доставки данных из источников в хранилище или вычислительную платформу.

Что важно на этом слое:

- регулярность загрузки;
- контроль форматов;
- обработка ошибок;
- дедупликация;
- временные метки;
- метаданные;
- безопасность доступа.


source → ingestion → raw / curated storage.

Все соглашения по извлечению данных вырабатываются практическими кейсами.



Слой хранения

Назначение слоя хранения – обеспечить долговременное, воспроизводимое и управляемое размещение данных.




PostgreSQL/ADPG удобно рассматривать как реляционный слой хранения и подготовки данных, а Data Lake — как слой гибкого хранения разнородных файлов.



Слой распределённой обработки

Определение

Apache Spark — распределённый вычислительный фреймворк для пакетной и потоковой обработки данных, SQL-аналитики и машинного обучения.




Подробная модель Spark будет темой отдельной лекции.

Spark выполняет тяжёлую обработку над большими наборами данных.



Слой ML, NLP и CV




Тезис. Машинное обучение в Big Data-системе — это не только алгоритм, но и воспроизводимый поток подготовки признаков, обучения, оценки и применения модели.



BI-слой

Определение

Business Intelligence — слой аналитической визуализации, отчётности и исследования метрик, предназначенный для принятия решений.



Superset и DataLens будут рассматриваться как разные инструменты одной концепции. Подключение к данным, построение датасета, визуализация, дашборд.



Слой мониторинга

Определение

Observability — способность понимать состояние информационной системы по её внешним сигналам, а именно метрикам, логам и трассам.



VI отвечает на вопрос «что происходит с бизнесом?»,
Слой мониторинга — «что происходит с системой,
которая обрабатывает данные?».




Раздел


Технологический стек курса



Карта технологий



Курс строится вокруг реалистичной, но посильной для студенческих устройств технологической цепочки.



Роль PostgreSQL и ADPG

PostgreSQL

Реляционная СУБД, удобная для хранения структурированных данных, SQL-запросов, ограничений целостности, индексов и аналитических витрин начального уровня.

Arenadata PostgreSQL и ADCM

Промышленная поставка и контур управления жизненным циклом таких компонентов, как: *развёртывание, конфигурирование, обслуживание, мониторинг.*

Для курса важно не только знать SQL, но и видеть, как СУБД становится частью инфраструктуры анализа данных.



Роль Spark и PySpark

Spark

Вычислительный слой, который позволяет обрабатывать данные распределённо, строить SQL-запросы, выполнять трансформации DataFrame и запускать ML-процессы.

PySpark

Python-интерфейс к Spark, позволяющий студенту работать с распределённой моделью вычислений в привычной языковой среде.

Программа на PySpark остаётся Spark-программой, а студент изучает модель распределённого выполнения без обязательного доступа к промышленному кластеру.



Роль BI и мониторинга

Superset / DataLens

Инструменты визуальной аналитики. Подключение к источнику, датасет, график, дашборд, фильтры, интерактивное исследование.

Prometheus / Grafana

Инструменты мониторинга. Метрики, временные ряды, запросы PromQL, дашборд состояния системы, система уведомлений.

Различие

BI визуализирует состояние бизнеса и данных. Мониторинг визуализирует состояние вычислительной системы.




Раздел

Итоги



Переход к лекции 2

Первая лекция дала общую архитектурную карту. Следующий шаг — подробно рассмотреть первый инженерный слой этой карты: хранение данных, PostgreSQL/ADPG и процессы ETL/ELT.



Контрольные вопросы

- 1 Почему Big Data нельзя корректно определить только через объём данных?
- 2 Чем вертикальное масштабирование отличается от горизонтального?
- 3 Зачем нужны partitioning и replication?
- 4 Почему OLTP и OLAP обычно разделяют архитектурно?
- 5 Чем Data Warehouse отличается от Data Lake?
- 6 В чём различие batch и stream processing?
- 7 Когда целесообразен ETL, а когда ELT?
- 8 Какую роль в курсе играют PostgreSQL, Spark, Superset и Prometheus?



Главные понятия лекции

На этой лекции введены:

- Big Data как относительная инженерная ситуация;
- шесть V-характеристик;
- вертикальное и горизонтальное масштабирование;
- partitioning, replication, distributed computing, fault tolerance;
- структурированные, полуструктурированные и неструктурированные данные;
- OLTP и OLAP;
- Data Warehouse, Data Lake, Data Mart, Lakehouse;
- batch и streaming;
- ETL и ELT;
- общий pipeline курса.



Спасибо за внимание!

