

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ

по дисциплине «Технологии и инструментарий анализа больших данных»

Практическая работа №5
Машинное обучение в анализе данных
с использованием Spark MLlib

Студент группы ИНБО-12-23, Албахтин И.В. _____
(подпись)

Преподаватель Приходько Н.А. _____
(подпись)

Москва 2026 г.

Содержание

1 Цель и задание 3
2 Данные и среда выполнения 3
3 Разбиение и подготовка признаков 4
4 Регрессия Calories 5
5 Бинарная классификация 6
6 Кластеризация тренировок 6
7 Проверка и выводы 7
Ответы на контрольные вопросы 8
Источники 14

1 Цель и задание

В работе построены три самостоятельных пайплайна PySpark на выбранном наборе Calories: регрессия расхода энергии, бинарная классификация тренировок и кластеризация по исходным характеристикам. Условия Moodle требуют свой набор данных; повторение демонстрации на Online Shoppers и Seoul Bike в сдаваемую работу не включено.

Полный Run All из нового ядра завершён 08.11.2026 16:39:02 МСК: 10 кодовых ячеек подряд, ошибок 0, время 49,13 с. Файл execution.json содержит последовательность счётчиков и SHA256 выполненного блокнота; verification.json фиксирует отдельную проверку исходных строк, разбиений и выгруженных метрик.

2 Данные и среда выполнения

Результаты приведены в таблице 1.

Таблица 1 – Паспорт данных и окружения

Параметр	Значение
Набор	Предоставленный calories.csv, 15 000 строк, 9 полей
Ключ	User_ID, все 15 000 значений уникальны
Пропуски	0
Совпадающие векторы предикторов	1
Стенд	TIABD-Albakhtin-IV; Ubuntu 22.04.5 LTS; 2 vCPU, 4 ГБ RAM
Python / Spark	3.10.12 / 3.5.7
Java	openjdk version "17.0.20.1" 2026-08-18

Схема задаётся явно: User_ID имеет тип Long, Gender - String, остальные поля - Double. До обучения сверяются SHA256 исходного CSV, число строк, уникальность ключей, NULL, допустимые категории и диапазоны. Источник предоставлен пользователем; лицензия и способ измерения Calories в исходных материалах не описаны.

Момент прогноза - окончание тренировки: известны Duration, Heart_Rate и Body_Temp. Дополнительные предикторы: Age, Height, Weight и Gender. Это оценка по завершённой тренировке, а не прогноз до её начала. User_ID,

Calories, обе цели и split исключены из признаков. Порог классификационной цели 200 ккал установлен заранее как условное правило учебной задачи.

3 Разбиение и подготовка признаков

Сортировка по SHA256(User_ID:42) формирует общие train, valid и test для двух прогнозных задач. Пересечения ключей проверены явно. Предобработка и параметры моделей обучаются на train, выбор выполняется на valid. Test используется только после фиксации модели и порога вероятности.

Результаты приведены в таблице 2.

Таблица 2 – Общие части и баланс классов

Часть	Строк	Calories < 200	Calories >= 200
train	9000	8555	445
valid	3000	2830	170
test	3000	2833	167

StringIndexer и OneHotEncoder кодируют Gender; одна из двух категорий опускается, чтобы избежать линейной зависимости с intercept. Неизвестная категория вызывает ошибку контракта. VectorAssembler объединяет шесть числовых полей с кодировкой, StandardScaler масштабирует без центрирования. Все стадии входят в один Pipeline и обучаются только на train.

На рисунке 1 показан результат выполнения на стенде.

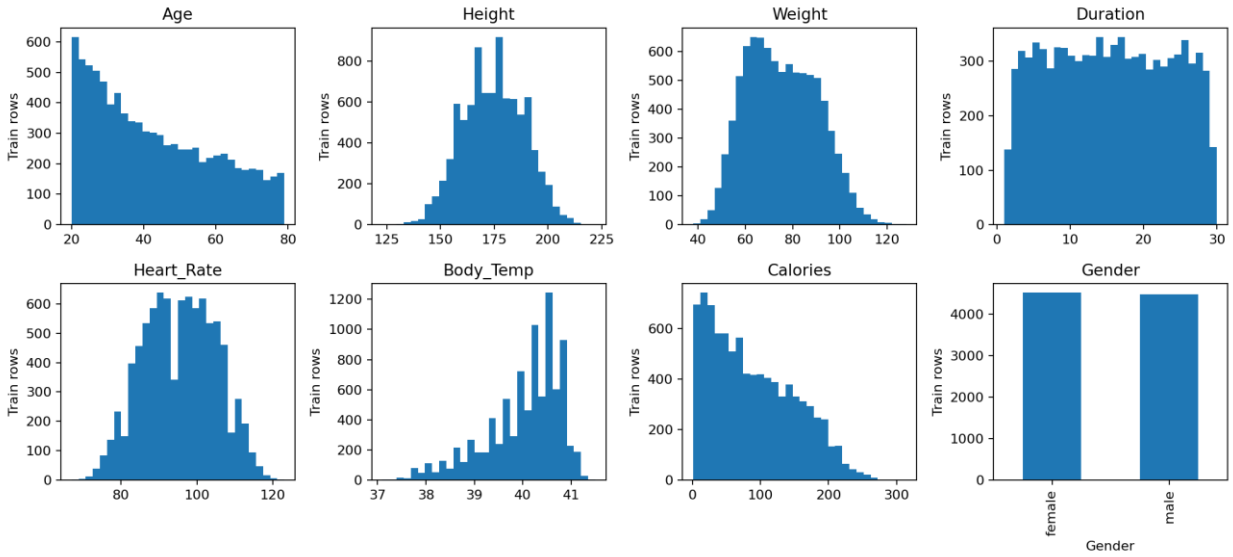


Рисунок 1 – Распределения предикторов и цели на train

4 Регрессия Calories

Сравниваются линейная регрессия с L2-регуляризацией 0,01 и 0,1 и случайный лес из 80 деревьев с глубиной 8 и 12. В лесах minInstancesPerNode=3, seed=42. Линейная модель использует normal solver. Критерий выбора - минимальный RMSE valid; базовое решение - среднее Calories train.

Результаты приведены в таблице 3.

Таблица 3 – Регрессоры на valid

Модель	RMSE ккал	MAE ккал	R^2
LR_0.01	11,499	8,416	0,9662
LR_0.1	11,496	8,409	0,9663
RF_8	5,784	3,747	0,9915
RF_12	4,104	2,455	0,9957

Результаты приведены в таблице 4.

Таблица 4 – Регрессия на test

Модель	RMSE ккал	MAE ккал	R^2
RF_12	4,115	2,388	0,9958
Среднее train	63,259	53,652	-0,0003

Выбрана RF_12. На 3 000 отложенных тренировках RMSE равен 4,115 ккал против 63,259 у базового решения. Этот результат относится к данному файлу и разбиению, не подтверждает достоверность измерений в клиническом применении.

На рисунке 2 показан результат выполнения на стенде.

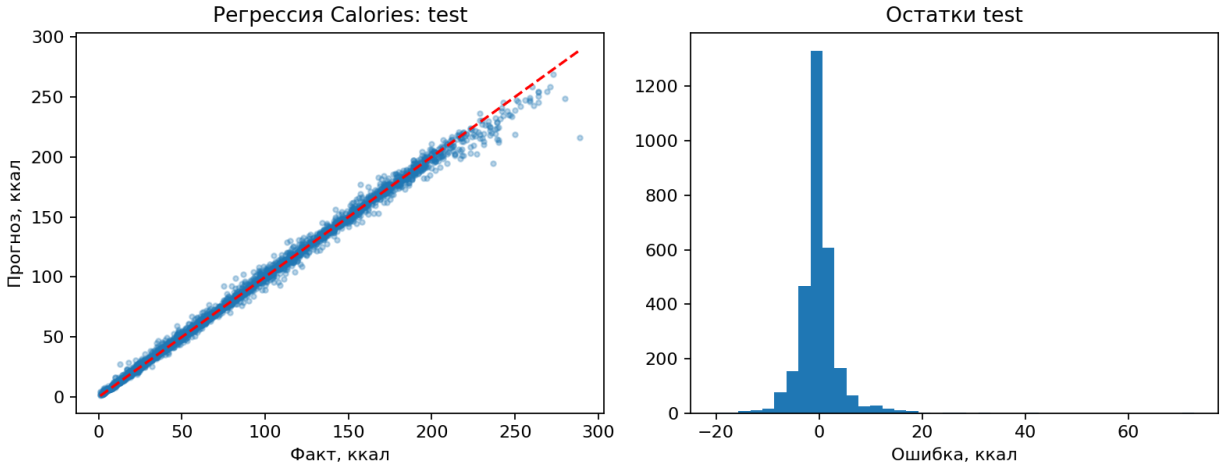


Рисунок 2 – Прогноз Calories и остатки на test

5 Бинарная классификация

Цель равна 1 при Calories >= 200. Сравниваются LogisticRegression с regParam 0,01 и 0,1 и RandomForestClassifier из 80 деревьев с глубиной 6 и 10. Модель выбирается по PR-AUC valid. Затем порог вероятности выбирается по F1 той же valid из 17 значений от 0,10 до 0,90. Порог цели не подбирается; он отличается от порога вероятности.

Результаты приведены в таблице 5.

Таблица 5 – Классификаторы на valid при пороге 0,5

Модель	PR-AUC	ROC-AUC	F1
LR_0.01	0,91192	0,99244	0,54701
LR_0.1	0,85256	0,98457	0,00000
RF_6	0,96846	0,99747	0,85333
RF_10	0,97347	0,99814	0,88959

Выбрана RF_10, порог вероятности 0,35. На test PR-AUC=0,97918, ROC-AUC=0,99882, precision=0,90449, recall=0,96407, F1=0,93333. Матрица: TN=2816, FP=17, FN=6, TP=161. Точность большинства train на том же test равна 0,94433; F1 - 0,00000.

На рисунке 3 показан результат выполнения на стенде.

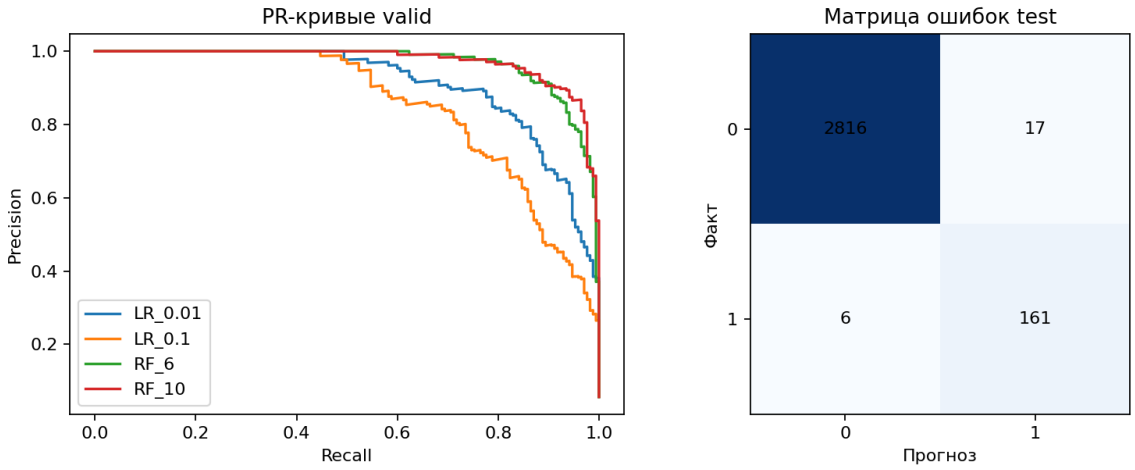


Рисунок 3 – PR-кривые valid и матрица ошибок test

6 Кластеризация тренировок

Описательный анализ использует все 15 000 строк и только Age, Height, Weight, Duration, Heart_Rate, Body_Temp. Gender, ключ и Calories исключены. Pipeline содержит VectorAssembler, StandardScaler с центрированием и

KMeans. Каждая модель обучается на всех строках; силуэт squaredEuclidean оценивается на одной фиксированной выборке 2 000 строк при k=2…8.

Результаты приведены в таблице 6.

Таблица 6 – Выбор числа кластеров

k	Силуэт	Training cost	Минимальная группа
2	0,46417	61 182,45	6552
3	0,42684	47 710,17	4767
4	0,39212	40 628,78	3265
5	0,39480	37 202,44	2060
6	0,37301	33 224,08	1953
7	0,37496	30 324,67	1582
8	0,36678	27 901,66	1573

По максимуму силуэта выбрано k=2. PCA используется только для визуализации, первые две компоненты объясняют 77,50% дисперсии. Средний Calories добавлен к профилям после обучения и не влияет на кластеры. Номера групп условны и не являются готовыми категориями тренированности.

Результаты приведены в таблице 7.

Таблица 7 – Профили групп

Группа	Строк	Возраст	Длительность	Пульс	Calories
0	8448	42,8	21,7	102,1	133,8
1	6552	42,8	7,6	87,0	32,5

На рисунке 4 показан результат выполнения на стенде.

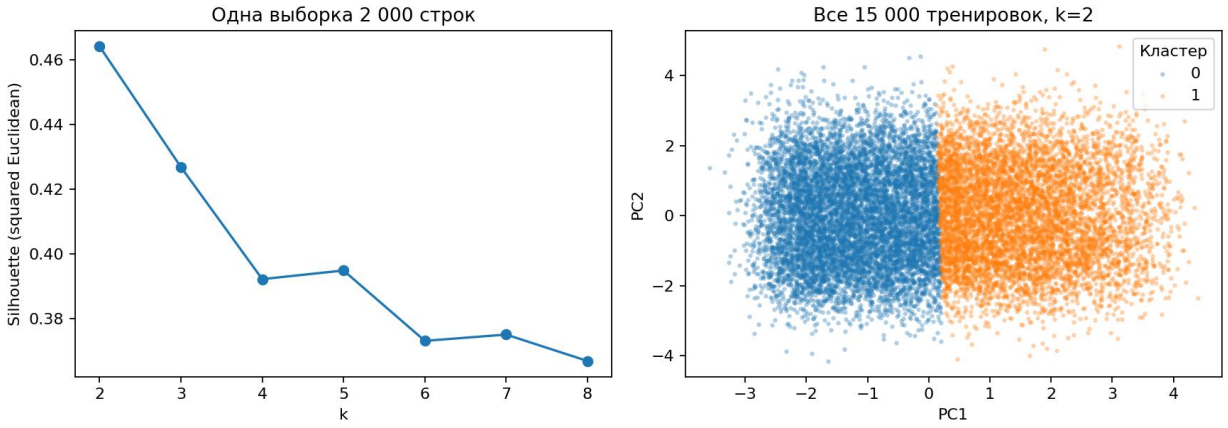


Рисунок 4 – Выбор k и PCA всех 15 000 тренировок

7 Проверка и выводы

Сохранены три полных PipelineModel, параметры выбора и прогнозы. После PipelineModel.load максимальная разность прогноза регрессии, вероятности классификации и номеров кластеров равна 0. В конце освобождён

кэш и остановлена SparkSession. Модели и исходный пользовательский CSV находятся локально и в учебной VM.

Независимый verify_pr5.py восстановил части по исходным ключам, сверил цели 3 000 тестовых строк в каждой прогнозной задаче, пересчитал RMSE, MAE, R^2, матрицы ошибок, ROC-AUC и PR-AUC. Проверены четыре классификатора valid, 17 порогов, train-only масштабы и все семь силуэтов на той же выборке. Профили покрывают 15 000 исходных тренировок.

Регрессия и классификация улучшили базовые решения на данном test. Кластеризация выявила геометрические группы по совместной изменчивости характеристик, а не клинические состояния. Ограничения: один split, неизвестное происхождение измерений и один вычислительный узел. Для оценки переноса нужны независимые данные; сеть и масштабирование физического кластера здесь не проверялись.

```
cd /home/albakhtin/tiabd/АлбахтинИВ/ML
/home/albakhtin/tiabd/.venv/bin/python run_notebook.py 5
/home/albakhtin/tiabd/.venv/bin/python verify_pr5.py
```

Ответы на контрольные вопросы

1. Чем параметр модели отличается от гиперпараметра? Приведите примеры для LR, RF и KMeans.

Параметр оценивается при обучении, гиперпараметр задаёт устройство или режим обучения и выбирается до итоговой проверки. У логистической регрессии параметры — коэффициенты и свободный член, гиперпараметры — сила и вид регуляризации. У случайного леса обучаются разбиения и значения листьев; задаются число деревьев и ограничения глубины. У KMeans обучаются центры, задаются k, инициализация и число итераций. Seed управляет воспроизводимостью.

2. Почему train, valid и test нельзя заменить одним случайным разбиением train/test во всех задачах?

Train обучает параметры, valid выбирает гиперпараметры и порог, test оценивает уже зафиксированное решение. Повторный выбор по test делает

оценку оптимистичной. Для временных данных случайное разбиение переносит информацию из будущего; для повторных наблюдений одного объекта нужны непересекающиеся группы. Valid можно реализовать внутренней кросс-валидацией, сохранив внешний test. В Seoul Bike использовано хронологическое разбиение.

3. Что называется утечкой данных и почему она может дать очень высокую, но бесполезную метрику?

Утечка возникает, когда обучение или выбор решения используют информацию, недоступную в реальный момент прогноза. Примеры — целевая переменная в признаках, заполнение пропусков по всему набору, один клиент в train и test, признаки после исхода события. Метрика измеряет доступ к ответу или зависимым наблюдениям, поэтому не переносится на новые данные.

4. Почему числовые коды Browser, Region и TrafficType рассматриваются как категории?

Цифры обозначают виды браузеров, регионы и источники трафика. Разность кодов не является расстоянием, а больший код не означает большего значения свойства. StringIndexer и OneHotEncoder кодируют принадлежность к категории без выдуманного числового порядка. Словарь кодирования обучается на train; обработка неизвестных категорий задаётся явно.

5. Что обучают StringIndexer, StandardScaler и сам классификатор внутри Pipeline?

StringIndexer определяет словарь категорий и их индексы. StandardScaler оценивает стандартные отклонения, а при withMean — также средние. Классификатор оценивает коэффициенты либо структуру деревьев. Pipeline.fit(train) последовательно обучает эти стадии на train. PipelineModel.transform(valid/test) применяет сохранённые преобразования без переобучения.

6. Почему accuracy около 0,85 почти ничего не доказывает для Online Shoppers?

Около 84,5% сессий не заканчиваются покупкой. Постоянный прогноз отрицательного класса уже даёт примерно такую accuracy, имея recall покупок 0. Нужны baseline, матрица ошибок, precision, recall, F1 и PR-AUC, а также стоимость ложных тревог и пропусков. Accuracy допустима как дополнительная метрика с учётом дисбаланса.

7. Как меняются precision и recall при повышении порога решения?

При фиксированных scores повышение порога уменьшает множество положительных решений: recall не увеличивается. Precision часто растёт, поскольку остаются более уверенные прогнозы, но строгой монотонности на конечной выборке нет. Порог выбирают на valid по бизнес-ограничению или критерию, затем фиксируют перед test. Порог 0,5 не является универсально оптимальным.

8. Почему PR-AUC особенно полезна при редком положительном классе?

Кривая precision–recall показывает компромисс между чистотой найденных положительных случаев и полнотой их обнаружения. Большое число истинно отрицательных не улучшает её напрямую, как accuracy. Ориентир случайного ранжирования связан с долей положительного класса. Следует указывать реализацию интегрирования: average precision и площадь по трапециям — разные оценки.

9. Что показывают коэффициенты логистической регрессии и почему их нельзя считать причинными эффектами?

При фиксированных остальных признаках коэффициент задаёт изменение логарифма шансов на единицу соответствующего преобразованного признака; $\exp(\beta)$ — отношение шансов. Значение зависит от масштаба, кодирования, корреляций и регуляризации. Наблюдательная связь не исключает смешивающие факторы и отбор, поэтому не доказывает эффект вмешательства.

10. Почему PageValues проверяется отдельным опытом? Как момент выдачи прогноза меняет список допустимых признаков?

PageValues связан с ценностью посещённых страниц и может содержать сведения, сформированные после конверсии. Без временного паспорта нельзя считать его доступным в начале сессии. Абляция сравнивает модель с этим признаком и без него на одном valid. Для раннего прогноза допустимы только сведения, уже известные к выбранному моменту; хорошая метрика не доказывает доступность признака.

11. Почему часы Functioning Day = No исключены из основной регрессии?

При закрытой системе нулевой прокат объясняется режимом работы, а не обычным спросом. Основная задача оценивает спрос в функционирующие часы. Прогноз для всей календарной сетки можно получить отдельным правилом: при закрытии 0, иначе прогноз регрессора. Фильтрация меняет область применимости модели и должна быть отражена в отчёте.

12. Зачем час кодируется одновременно через sin и cos?

Пара $\sin(2\pi h/24)$, $\cos(2\pi h/24)$ сохраняет цикличность: часы 23 и 0 становятся соседними. Один sin неоднозначен для разных часов, а два компонента различают положение на окружности. Это помогает линейной модели описать суточный цикл без искусственного разрыва между концом и началом суток.

13. В каком смысле PolynomialExpansion делает зависимость нелинейной?

Расширение добавляет степени и произведения исходных признаков. Линейный регрессор остаётся линейным по обучаемым коэффициентам, но прогноз становится полиномиальной функцией исходных переменных: например $\beta_0 + \beta_1 x + \beta_2 x^2$. Растёт число признаков и риск переобучения; степень и регуляризацию выбирают на valid.

14. Чем MAE отличается от RMSE? Какая метрика сильнее реагирует на пики ошибки?

MAE = mean(|y − ŷ|), RMSE = sqrt(mean((y − ŷ)²)). Обе измеряются в единицах цели. Квадрат сильнее увеличивает вклад больших ошибок, поэтому RMSE чувствительнее к пикам. Совместный просмотр метрик и остатков помогает отличать типичную ошибку от редких крупных промахов.

15. Как понимать отрицательный R^2 на test?

$R^2 = 1 - SSE/SST$. Отрицательное значение означает, что сумма квадратов ошибок модели больше, чем у постоянного прогноза средним самой тестовой цели. Это не отрицательная вероятность и не техническая ошибка само по себе: возможны плохая модель или сдвиг распределения. Практический baseline следует обучать на train, а не вычислять его прогноз по test.

16. Почему простое среднее по часу является более сильным baseline, чем глобальное среднее?

Часовое среднее учитывает регулярный суточный профиль спроса: пики поездок и ночной спад. Глобальное среднее выдаёт одинаковое значение для всех часов. Таблица средних вычисляется только по train; для отсутствующего часа нужен заранее заданный fallback. Сезонный сдвиг может ухудшить оба правила, поэтому их сравнивают на том же временном test.

17. Почему day_index может помочь на одном году и стать проблемой при переносе на другой?

Индекс дня отражает положение внутри наблюдаемого периода и способен захватить тренд или сезонную корреляцию. За пределами диапазона линейная модель экстраполирует эту связь, а деревья не продолжают её естественным образом. В новом году индекс не обязан иметь тот же смысл. Нужны календарные циклы, длительная временная проверка и контроль сдвига.

18. Почему trainingCost KMeans нельзя использовать как единственный критерий выбора k?

Сумма квадратов расстояний до центров обычно убывает при увеличении k и может поощрять бессодержательное дробление. Поэтому рассматривают локоть, силуэт, минимальные размеры и интерпретируемость групп. Сравнение проводится при одинаковых признаках и масштабировании; проверяется устойчивость к seed и изменению данных.

19. Что означает отрицательный, нулевой и положительный silhouette?

Для объекта $s = (b - a)/\max(a,b)$, где a — среднее расстояние внутри своей группы, b — минимальное среднее расстояние до другой группы. Значение около 1 соответствует компактной отделённой группе, около 0 — границе, отрицательное — большей близости к другой группе. Среднее зависит от метрики и выборки; это не доля правильных ответов.

20. Почему Revenue нельзя включать в features кластеризации, если после обучения мы хотим сравнить долю покупок?

Тогда покупка непосредственно повлияет на построение групп, и различие долей окажется частично заложенным в алгоритм. Для поведенческой сегментации Revenue исключают из признаков и используют после обучения только для описания групп. Аналогично исключён PageValues, тесно связанный с конверсией.

21. Почему PCA-проекция не доказывает, что кластеры полностью разделены в исходном восьмимерном пространстве?

PCA оставляет направления максимальной дисперсии и отбрасывает остальные. Объекты могут наложиться на плоскости при различии в отброшенных измерениях; видимые промежутки также не доказывают устойчивую кластерную структуру. Следует сообщать объяснённую дисперсию и считать расстояния и силуэт в исходном пространстве кластеризации.

22. Какие данные допустимо передавать через toPandas(), а какие должны оставаться распределёнными?

Допустимы небольшие агрегаты, таблицы метрик и ограниченные выборки для графиков, объём которых заведомо помещается в память driver. Большие исходные таблицы, JOIN и промежуточные массивы должны обрабатываться в Spark. toPandas собирает данные на одном процессе; Arrow ускоряет перенос, но не устраняет ограничение памяти.

23. Что необходимо сохранить вместе с PipelineModel, чтобы решение можно было применить повторно?

Нужны схема и порядок входных полей, смысл и момент доступности признаков, версия среды, порог классификации, параметры конфигурации, описание источника и контрольные суммы. PipelineModel хранит обученные преобразования и саму модель. После load проверяют прогноз на контрольных объектах; числовой порог, установленный вне модели, применяют отдельно.

24. Какие отличия численных метрик между двумя версиями Spark допустимы, а какие указывают на ошибку в данных или коде?

Небольшие изменения возможны из-за порядка редукций double, оптимизаторов, реализации деревьев и приближённой площади под кривой. Seed не гарантирует побитового совпадения между версиями. Изменение числа строк, утечка между частями, другая схема, неверные категории или единицы — ошибки постановки либо данных. Сначала сверяют хэши, разбиение и параметры, затем объясняют численную разницу.

Источники

1. Практическая работа №5. Предоставленная методичка, ml_labs/assignment.

2. Moodle. Условия сдачи ПР5 от 08.11.2026.

3. Calories. Предоставленный calories.csv; SHA256 и схема в ML/source_manifest.json.

4. Apache Spark 3.5.7 ML Pipelines