

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра квантовых информационных технологий, практической и прикладной информатики (ККИТПиПИ)

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ

по дисциплине «Технологии и инструментарий анализа больших данных»

Практическая работа №6
Кластеризация

Студент группы ИНБО-12-23, Албахтин И.В. _____ (подпись)

Преподаватель Приходько Н.А. _____ (подпись)

Москва 2026 г.

Содержание

1 Цель и задание 3
2 Данные и подготовка 3
3 KMeans и выбор k 4
4 Иерархическая кластеризация 5
5 DBSCAN 6
6 Визуализация и сравнение 7
7 Выводы и воспроизводимость 9
Источники 9

1 Цель и задание

Цель — сравнить три подхода к кластеризации: KMeans, иерархический метод и DBSCAN. Выполнены все шесть пунктов задания: выбор данных, масштабирование, локоть и силуэт для k, иерархия, плотностный алгоритм, t-SNE и содержательная интерпретация. Истинная метка сорта не участвует в обучении и подборе.

Полный Run All из нового ядра завершён 26.10.2026 00:43:58 МСК: 6 кодовых ячеек подряд, ошибок 0, время 46,89 с. Файл execution.json содержит последовательность счётчиков и SHA256 выполненного блокнота; verification.json фиксирует отдельную проверку исходных строк, разбиений и выгруженных метрик.

2 Данные и подготовка

Использован предоставленный Dry_Bean.csv: 13 611 объектов фасоли, 16 числовых морфологических признаков и Class с семью сортами. Признаки включают площадь, периметр, длины осей, эксцентриситет, компактность и коэффициенты формы. Набор отличается от данных других личных практик; неповторяемость во всей учебной группе требует сверки с её реестром.

Результаты приведены в таблице 1.

Таблица 1 – Паспорт данных и среды

Параметр	Значение
Строки / признаки	13 611 / 16
NULL	0
Совпадающие векторы признаков	68
Python / scikit-learn	3.10.12 / 1.7.2
Ресурсы	2 vCPU, 4 ГБ RAM; Ubuntu VM
Seed	42

68 повторяющихся векторов сохранены: отсутствие идентификаторов не позволяет доказать ошибочное дублирование наблюдений. Все три алгоритма обучаются на полном наборе. StandardScaler преобразует x в (x−mean)/std по всем неразмеченным объектам, поскольку проводится описательная

кластеризация. Масштаб важен: площадь и коэффициенты формы имеют несопоставимые исходные единицы.

```
features = [c for c in raw.columns if c != 'Class']
X = StandardScaler().fit_transform(raw[features])
# Class используется только после фиксации разбиений
```

На рисунке 1 показан результат выполнения на стенде.

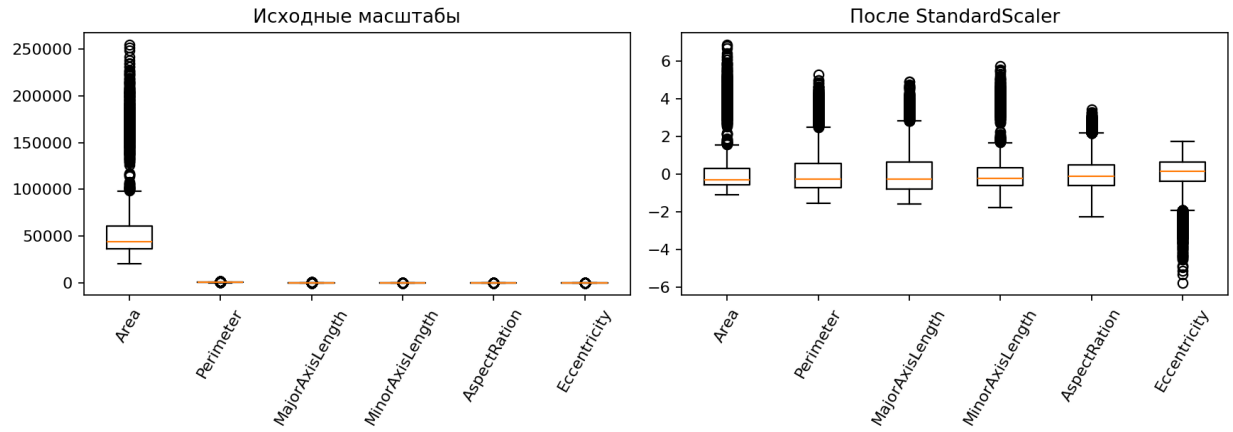


Рисунок 1 – Различие исходных масштабов и результат стандартизации

Для дорогого расчёта силуэта заранее выбраны 4 000 индексов генератором default_rng(42); выборка одинакова для всех вариантов и сохранена в summary.json. Евклидовы расстояния считаются в 16-мерном стандартизованном пространстве. Силуэт на двумерной картинке не используется.

3 KMeans и выбор k

Для k от 2 до 10 выполнено по 20 инициализаций KMeans, random_state=42. Сохраняются inertia и минимальный/максимальный размер группы. Убывание inertia рассматривается по правилу локтя, окончательный критерий — максимальный силуэт. Семь известных сортов не используются для назначения k.

Результаты приведены в таблице 2.

Таблица 2 – Подбор числа кластеров

k	Inertia	Силуэт	Мин размер	Макс размер
2	129 900,0	0,3996	5 580	8 031
3	94 742,0	0,4087	524	7 579
4	76 474,3	0,3456	524	5 874
5	61 893,6	0,3615	521	5 858

k	Inertia	Силуэт	Мин размер	Макс размер
6	55 050,1	0,3650	520	5 804
7	48 812,0	0,3165	520	3 157
8	45 241,6	0,3124	452	3 164
9	41 975,6	0,3121	438	3 140
10	39 771,2	0,2934	434	2 624

На рисунке 2 показан результат выполнения на стенде.

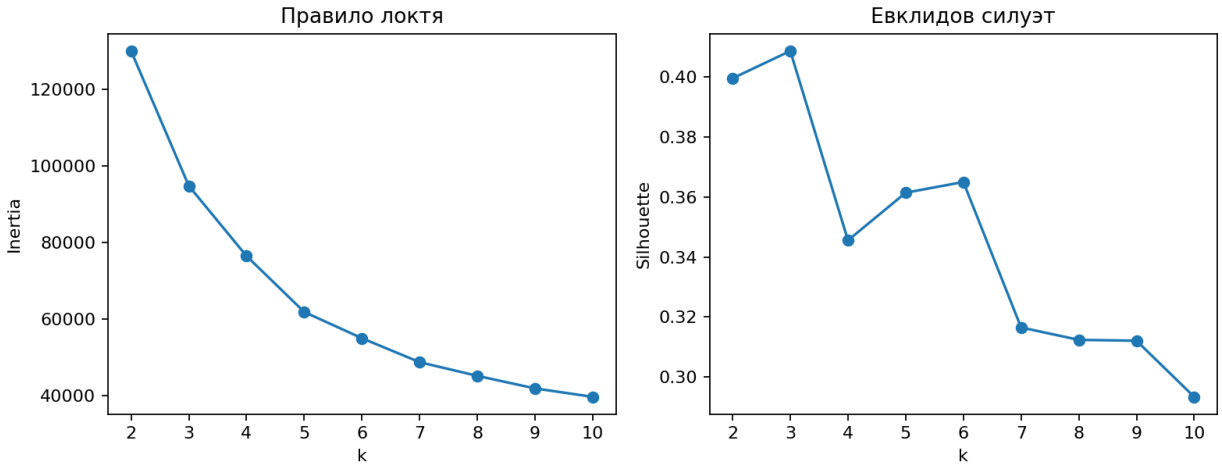


Рисунок 2 – Локоть и средний силуэт KMeans

Максимум силуэта достигнут при k=3: 0,4087. На локте заметно уменьшение выигрыша после нескольких крупных групп, но однозначного доказательства единственного истинного k график не даёт. KMeans выделяет геометрические группы, которые не обязаны совпасть с сортами.

4 Иерархическая кластеризация

Построено полное дерево методом Ward по всем 13 611 строкам: 13 610 слияний. Ward выбирает объединение с минимальным приростом внутрикластерной суммы квадратов. Для сопоставления используется срез на том же k=3, выбранном без Class. Визуальная дендрограмма показывает последние 30 объединений; дерево при обучении не сокращено.

```
tree = linkage(X, method='ward', metric='euclidean')
labels = fcluster(tree, t=3, criterion='maxclust') - 1
# Полная матрица слияний сохранена в hierarchy_linkage.csv
```

На рисунке 3 показан результат выполнения на стенде.

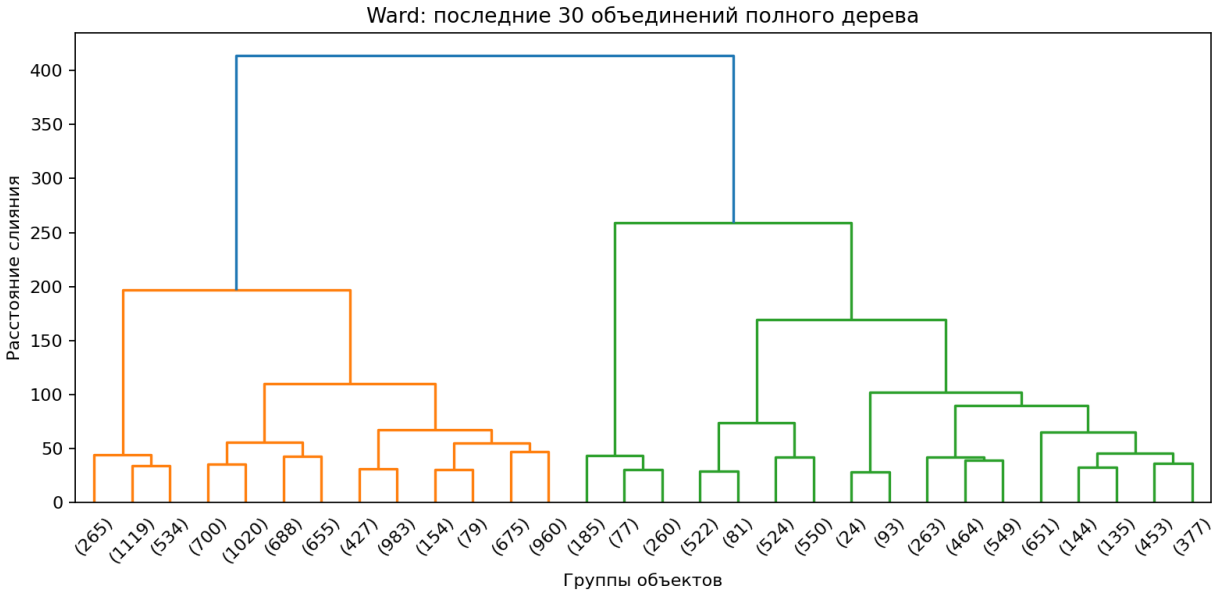


Рисунок 3 – Дендрограмма Ward по полному набору

Квадратичная по числу объектов память иерархии ограничивает перенос на существенно больший набор. На данном стенде полное дерево помещается в память; подмена задачи обучением на маленькой выборке не использовалась.

5 DBSCAN

Сначала построена кривая расстояний до 10-го соседа. Перебраны eps=0,5; 0,7; 0,9; 1,1; 1,3; 1,5; 1,8; 2,1 при min_samples=5 и 10. Среди вариантов не менее чем с двумя кластерами и покрытием от 80% выбран максимальный силуэт без шума; доля шума оценивается отдельно.

На рисунке 4 показан результат выполнения на стенде.

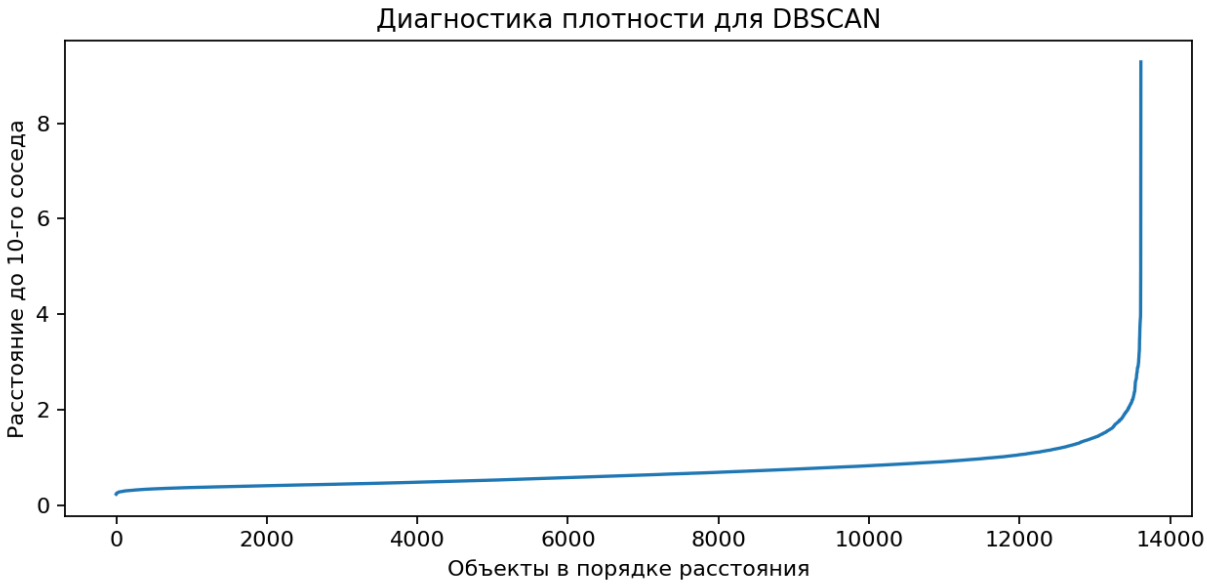


Рисунок 4 – Расстояния до десятого соседа в стандартизованном пространстве

Результаты приведены в таблице 3.

Таблица 3 – Настройка DBSCAN

eps	min_samples	Кластеры	Шум	Покрытие	Силуэт
0,9	10	2	1 400	0,8971	0,5874

Полная сетка из 16 вариантов сохранена в dbscan_selection.csv. Малый eps дробит данные и объявляет шумом большую часть объектов; большой eps сливает почти всё в один кластер. Выбранная настройка оставляет 1 400 шумовых объектов, поэтому её силуэт нельзя сравнивать с полным покрытием KMeans без этой оговорки.

6 Визуализация и сравнение

t-SNE построен по всем 13 611 стандартизованным векторам: perplexity=40, max_iter=1000, init=pca, random_state=42. Одна и та же проекция окрашена тремя способами. Проекция не участвует в обучении кластеризаторов и подборе параметров; локальное сходство на плоскости не гарантирует сохранения глобальных расстояний.

На рисунке 5 показан результат выполнения на стенде.

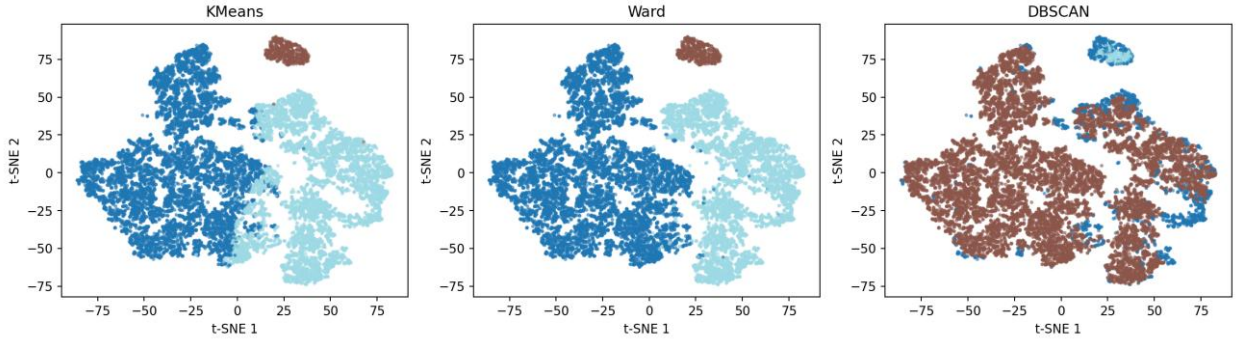


Рисунок 5 – Одна t-SNE проекция с разбиениями KMeans Ward и DBSCAN

Результаты приведены в таблице 4.

Таблица 4 – Сравнение разбиений

Алгоритм	Групп	Шум	Силуэт	ARI	NMI
KMeans	3	0	0,4087	0,2985	0,4862
Ward	3	0	0,4074	0,3325	0,5503
DBSCAN	2	1 400	0,5874	0,0461	0,1252

ARI и NMI рассчитаны после фиксации разбиений по справочной Class; по ним параметры не подбирались. DBSCAN даёт высокий силуэт двух крупных плотностных групп, но низкое совпадение с семью сортами. Это не делает его лучшим решением любой задачи. KMeans и Ward имеют близкие силуэты, при этом Ward несколько лучше согласуется со справочными метками в данном опыте.

Результаты приведены в таблице 5.

Таблица 5 – Средние морфологические профили

Алгоритм	Группа	Area	Perimeter	Compactness
KMeans	0	37 416,2	714,54	0,8377
KMeans	1	173 264,8	1 584,64	0,7927
KMeans	2	63 121,2	979,56	0,7486
Ward	0	38 113,7	723,07	0,8313
Ward	1	173 485,1	1 585,62	0,7926
Ward	2	65 569,4	1 002,42	0,7469
DBSCAN	-1	81 991,5	1 079,96	0,7740
DBSCAN	0	47 332,9	814,86	0,8029
DBSCAN	1	168 284,2	1 554,70	0,7985

Профили позволяют описать размер и форму фасоли в полученных группах. Метка −1 у DBSCAN обозначает шум и не является сортом. Полные средние всех 16 полей и размеры групп находятся в отдельных CSV; номера групп разных алгоритмов не сопоставляются напрямую.

7 Выводы и воспроизводимость

Масштабирование устранило доминирование площади и периметра. По заявленному критерию выбран k=3; независимая иерархия построена без сокращения данных. DBSCAN выделил две плотностные группы при покрытии 89,71%, но с более слабым соответствием сортам. Различие геометрического и предметного критериев требует содержательной интерпретации, а не выбора по одному максимальному числу.

Сохранены полные назначения объектов, координаты t-SNE, дерево Ward, сетки параметров и профили. В models/pr6/clustering.joblib на VM сохранены scaler, KMeans, DBSCAN и дерево. После загрузки прогноз KMeans совпал для всех объектов. Отдельная проверка пересчитала три силуэта на фиксированной выборке, размеры шума и срез полного дерева.

```
cd /home/albakhtin/tiabd/АлбахтинИВ/ML
/home/albakhtin/tiabd/.venv/bin/python run_notebook.py 6
/home/albakhtin/tiabd/.venv/bin/python verify_results.py
```

Источники

1. Практическая работа №6. Предоставленная методичка, ml_labs/assignment.

2. Dry_Bean.csv. Предоставленный архив Dry_Bean.csv.zip; SHA256 в ML/source_manifest.json.

3. scikit-learn. Clustering. https://scikit-learn.org/stable/modules/clustering.html

4. SciPy. Hierarchical clustering linkage. https://docs.scipy.org/doc/scipy/reference/generated/scipy.cluster.hierarchy.linkage.html