

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра квантовых информационных технологий, практической и прикладной информатики (ККИТПиПИ)

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ

по дисциплине «Технологии и инструментарий анализа больших данных»

Практическая работа №7
Ансамблевое обучение

Студент группы ИНБО-12-23, Албахтин И.В. _____ (подпись)

Преподаватель Приходько Н.А. _____ (подпись)

Москва 2026 г.

Содержание

1 Цель и задание 3
2 Среда и данные 3
3 Разбиение без пересечения подкастов 4
4 Бэггинг и бустинг 5
5 Качество на test 6
6 Время обучения 7
7 Сохранение и выводы 7
Источники 8

1 Цель и задание

Цель — реализовать бэггинг и бустинг на одном регрессионном наборе и сравнить качество и время работы. Прогнозируется Listening_Time_minutes по характеристикам подкаста. Обе модели используют одни признаки, одни train/valid/test и одинаковую подготовку. Дополнительно проверены среднее train и одиночное дерево.

Полный Run All из нового ядра завершён 26.10.2026 00:44:13 МСК: 5 кодовых ячеек подряд, ошибок 0, время 13,96 с. Файл execution.json содержит последовательность счётчиков и SHA256 выполненного блокнота; verification.json фиксирует отдельную проверку исходных строк, разбиений и выгруженных метрик.

2 Среда и данные

Результаты приведены в таблице 1.

Таблица 1 – Паспорт выполнения

Параметр	Значение
Стенд	Ubuntu 22.04.5 LTS, TIABD-Albakhtin-IV
Ресурсы	2 vCPU, 4 ГБ RAM, CPU
Python / scikit-learn	3.10.12 / 1.7.2
Notebook	Practice_7.ipynb, последовательный Run All
Исходные данные	podcast_dataset.csv, 52 500 строк и 11 полей

Измерения этого отчёта получены в указанной VM. Методичка предусматривает ColabNotebook: подготовленный .ipynb совместим с Colab, где исходный CSV следует загрузить в data/ либо рабочий каталог. Запуск VM подтверждён протоколом; результаты не выдаются за замеры облачного CPU или GPU.

Набор предоставлен пользователем в Podcast Dataset.zip. Цель измеряется в минутах. Используются Episode_Length_minutes, Host_Popularity_percentage, Guest_Popularity_percentage, Number_of_Ads и категории Genre, Publication_Day, Publication_Time, Episode_Sentiment. Сценарий предполагает, что контентные метаданные известны к публикации.

При позднем происхождении Episode_Sentiment его нужно исключить до прикладного применения.

Результаты приведены в таблице 2.

Таблица 2 – Контроль качества

Проверка	Результат
Исходные строки	52 500
Удалены точные дубликаты	2 500
Затем удалены строки без цели	5 132
Осталось	44 868
Подкастов	48
Неоднозначные пары названия и эпизода	4 790

В исходном файле пропущено 5 395 значений цели, 5 246 длин эпизода и 5 258 значений популярности гостя. После удаления точных копий остаётся 5 132 строки без цели; их исключают, не заполняя ответы. Числовые предикторы заполняются медианами только train. Одинаковая пара Podcast_Name/Episode_Title имеет разные длины и не считается надёжным идентификатором наблюдения.

3 Разбиение без пересечения подкастов

GroupShuffleSplit с random_state=42 сначала выделяет 20% групп для test, затем 25% оставшихся групп для valid. Целые Podcast_Name попадают только в одну часть. Это проверяет перенос на новые подкасты. Podcast_Name и Episode_Title исключены из предикторов; они не становятся признаками скрытого запоминания. Временное разбиение невозможно обосновать по названию дня недели без календарной даты.

Результаты приведены в таблице 3.

Таблица 3 – Общие части для всех моделей

Часть	Строк	Подкастов
train	26 377	28
valid	9 245	10
test	9 246	10

```
train_valid, test = next(GroupShuffleSplit(test_size=.2,
    random_state=42).split(data, groups=data.Podcast_Name))
# Второй групповой split отделяет valid от train_valid
# Пересечения множеств Podcast_Name проверены assert
```

На рисунке 1 показан результат выполнения на стенде.

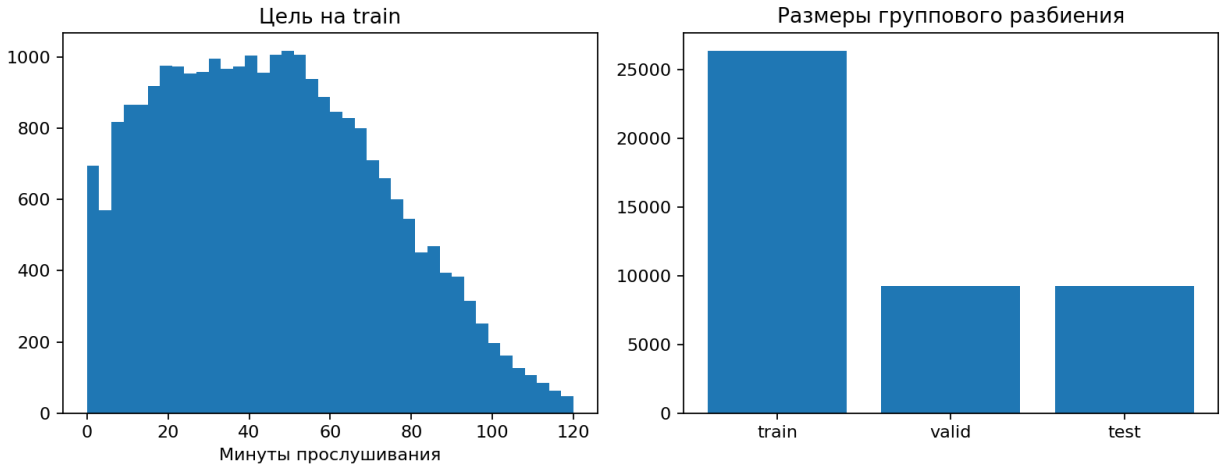


Рисунок 1 – Распределение цели train и объёмы частей

4 Бэггинг и бустинг

Общая предобработка: медианное заполнение четырёх числовых признаков и OneHotEncoder(handle_unknown=ignore) для четырёх категориальных. Подготовка и регрессор объединены в Pipeline. Все стадии fit вызываются только на train; valid определяет параметры, test не используется при выборе.

BaggingRegressor усредняет независимые DecisionTreeRegressor, обученные на bootstrap-выборках объёма 80% train. Сравниваются 50 деревьев глубины 8 и 80 деревьев глубины 12, min_samples_leaf=5, n_jobs=2. HistGradientBoostingRegressor последовательно уточняет прогноз; сравниваются 100 итераций, learning_rate=0,05, 15 листьев и 200 итераций, learning_rate=0,08, 31 лист. l2_regularization=1, early_stopping=False, random_state=42.

Выбран CPU-вариант градиентного бустинга для табличной регрессии. Пример CatBoost на GPU в теоретической части иллюстрирует другую конфигурацию; практическое задание требует бэггинг и бустинг на одних данных, не предписывая единственную библиотеку. Итоговые показатели зависят от выбранных ограничений моделей.

Результаты приведены в таблице 4.

Таблица 4 – Выбор по RMSE valid

Модель	RMSE мин	MAE мин	R^2
Бэггинг 50 / глубина 8	13,838	10,295	0,7482
Бэггинг 80 / глубина 12	13,894	10,322	0,7462
Бустинг 100 / lr 0.05	13,764	10,254	0,7509
Бустинг 200 / lr 0.08	13,825	10,282	0,7487
Среднее train	27,580	23,040	-0,0000
Одиночное дерево	15,228	11,250	0,6951

В каждом семействе выбрана конфигурация с минимальным RMSE valid: бэггинг из 50 деревьев глубины 8 и бустинг из 100 итераций с learning_rate=0,05. Более сложные варианты не улучшили эту оценку. Параметры зафиксированы до итоговой проверки.

5 Качество на test

Результаты приведены в таблице 5.

Таблица 5 – Результаты на одинаковом test

Модель	RMSE мин	MAE мин	R^2
Бэггинг 50 / глубина 8	13,652	10,171	0,7481
Бустинг 100 / lr 0.05	13,595	10,136	0,7502
Среднее train	27,218	22,733	-0,0012
Одиночное дерево	15,037	11,169	0,6944

Бэггинг: RMSE 13,652 мин; бустинг: 13,595 мин. Разница 0,057 мин мала относительно общей ошибки. Оба ансамбля заметно лучше среднего train и одиночного дерева на этом разбиении. Один test без повторной групповой оценки не доказывает статистически значимое превосходство семейства во всех данных.

На рисунке 2 показан результат выполнения на стенде.

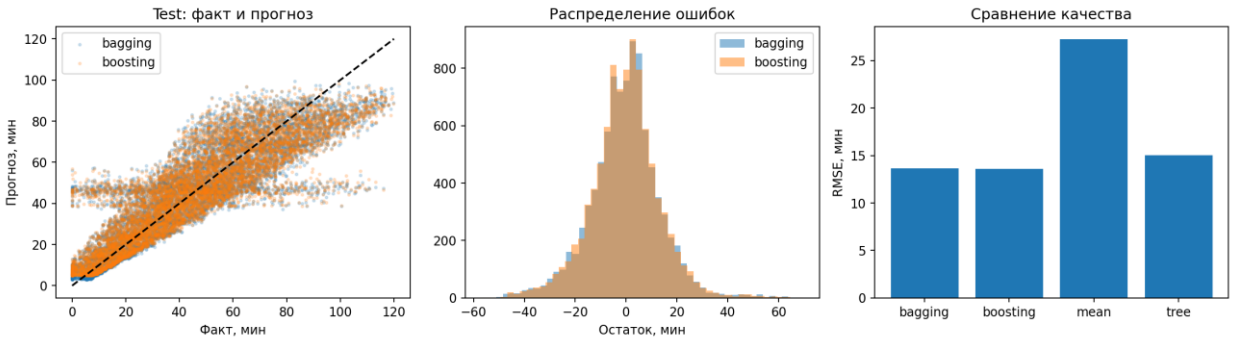


Рисунок 2 – Факт прогноз остатки и RMSE четырёх моделей на test

6 Время обучения

Для каждой выбранной конфигурации выполнены три повторных fit на неизменной train с тем же seed. Каждый замер включает общую предобработку и модель, но исключает чтение CSV, подбор и построение графиков. Медиана уменьшает влияние одиночного всплеска. Все замеры относятся к двум CPU одного стенда, без GPU и сравнения между разными машинами.

Результаты приведены в таблице 6.

Таблица 6 – Повторы обучения и прогноз test

Модель	Fit 1 с	Fit 2 с	Fit 3 с	Медиана с	Predict с
Бэггинг	0,9543	0,9285	0,9078	0,9285	0,1289
Бустинг	0,2238	0,2235	0,2541	0,2238	0,0196

На рисунке 3 показан результат выполнения на стенде.

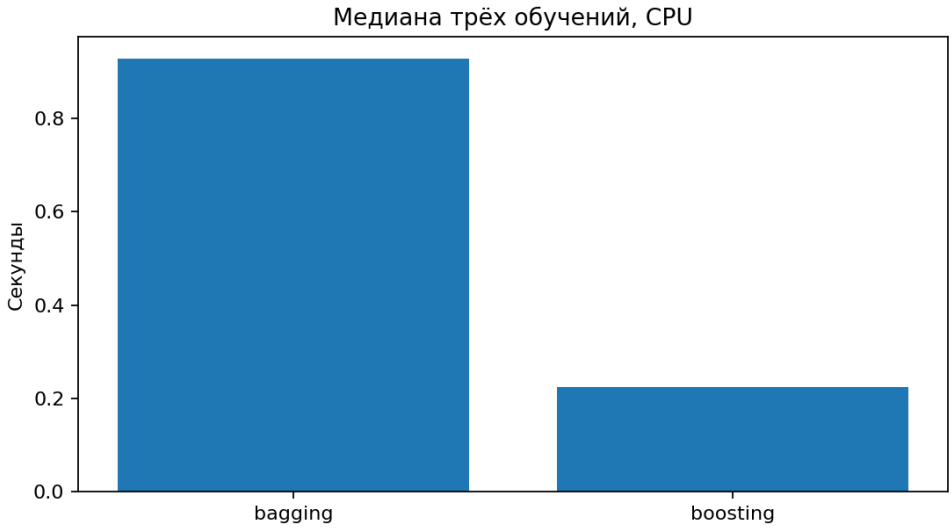


Рисунок 3 – Медианы трёх обучений на CPU

В данной серии бустинг обучался быстрее примерно в 4,15 раза. Это сравнение конкретных конфигураций: число и глубина деревьев, гистограммная реализация и параллелизм влияют на стоимость. Короткая серия с фиксированным порядком не является универсальным рейтингом алгоритмов.

7 Сохранение и выводы

Обе выбранные Pipeline сохранены через joblib вместе с медианами и словарями категорий. Повторное чтение моделей воспроизвело прогноз с абсолютным допуском 10^{-12}. Экспортированы параметры valid, все test-

прогнозы, таблицы метрик, групповой состав частей и временные повторы. Исходный CSV и бинарные модели остаются локально и в VM; исходники и доказательства запуска доступны в репозитории.

Бэггинг уменьшил ошибку одиночного дерева усреднением независимых моделей. Бустинг достиг близкого и немного меньшего RMSE с меньшим временем в этой серии. Достоверность сравнения обеспечивают общие данные, групповое разбиение и обучение подготовки только на train. Ограничения: неоднозначные идентификаторы эпизодов, пропуски, неизвестный временной паспорт части метаданных и отсутствие календарной даты для временной проверки.

Отдельный verify_results.py восстановил 44 868 оставшихся строк, проверил непересечение 28/10/10 подкастов, совпадение цели test с исходником, медианы train и все четыре набора регрессионных метрик. Уникальность набора во всей учебной группе проверяется по её реестру; в личном комплекте этот набор используется только для ПР7.

```
cd /home/albakhtin/tiabd/АлбахтинИВ/ML
/home/albakhtin/tiabd/.venv/bin/python run_notebook.py 7
/home/albakhtin/tiabd/.venv/bin/python verify_results.py
```

Источники

1. Практическая работа №7. Предоставленная методичка, ml_labs/assignment.

2. Podcast Dataset.zip, podcast_dataset.csv. Предоставленный набор; SHA256 в ML/source_manifest.json.

3. scikit-learn. Ensemble methods. https://scikit-learn.org/stable/modules/ensemble.html

4. scikit-learn. GroupShuffleSplit. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupShuffleSplit.html

5. Google Colaboratory. https://colab.research.google.com/